



T.C.
İSTANBUL TOPKAPI
ÜNİVERSİTESİ
MÜHENDİSLİK VE DOĞA
BİLİMLERİ FAKÜLTESİ
YAZILIM MÜHENDİLİĞİ BÖLÜMÜ

Üniversite Öğrencileri için AI Destekli Stres Tahmin Sistemi

İsmail Can GÜNAY
21040301040

BİTİRME PROJESİ

İSTANBUL 2026

Projenin Danışmanı :
Jüri Üyesi :
Jüri Üyesi :

AKADEMİK DÜRÜSTLÜK BEYANI

Mezuniyet projesi olarak sunduğum “**Üniversite Öğrencileri için AI Destekli Stres Tahmin Sistemi**” başlıklı çalışmanın, bilimsel ahlak ve geleneklere uygun olarak tarafımdan yazıldığını, yararlandığım eserlerin tamamının kaynaklarda gösterildiğini ve çalışmam içerisinde kullanıldıkları her yerde atıf yapıldığını belirtir ve onurumla doğrularım.

01/04/2026

İsmail Can GÜNAY

TEŞEKKÜR

Çalışmalarım süresince bilimsel katkıları ile beni aydınlatan, farklı bakış açıları ile yol gösteren, yakın ilgi ve yardımları ile beni motive eden ve bu günlere gelmemde en büyük katkı sahibi olan sayın **Dr. Öğr. Üyesi Gökalep TULUM’a** teşekkürü bir borç bilirim.

Ayrıca, çalışmalarım süresince sabır göstererek beni daima destekleyen değerli aileme ve arkadaşlarıma en içten teşekkürlerimi sunarım.

01/04/2026

İsmail Can GÜNAY

ÖZET

Bu çalışmada, üniversite öğrencilerinin stres düzeylerini anket ve yaşam alışkanlığı verileri üzerinden tahmin edebilen web tabanlı bir karar destek sistemi ele alınmıştır. Çalışmanın temel problemi, öğrenci stresinin çoğu zaman yalnızca dönemsel anketler veya öznel değerlendirmelerle izlenmesi; buna karşılık çok boyutlu veriyi anlamlı, izlenebilir ve kullanıcıya fayda sağlayacak bir dijital yapıya dönüştüren bütünleşik sistemlerin sınırlı olmasıdır.

Bu kapsamda projede, **University Student Stress Dataset** kullanılarak öğrencilerin stres düzeyleri **Düşük, Orta ve Yüksek** olarak sınıflandırılmıştır. Modelleme sürecinde **Logistic Regression, Random Forest ve XGBoost** algoritmaları karşılaştırılmış; çapraz doğrulama ve test sonuçlarına göre nihai model olarak **Logistic Regression** seçilmiştir. Veri sızıntısı riskini önlemek amacıyla **Stress_Score** değişkeni model eğitime dahil edilmemiş, ana hedef değişken olarak **Stress_Level** kullanılmıştır.

Geliştirilen sistem yalnızca sınıflandırma çıktısı üretmekle sınırlı değildir. Kullanıcı kayıt ve giriş işlemleri, stres değerlendirme formu, sonuç ekranı, kısa öneri sunumu, geçmiş kayıtların saklanması ve haftalık/aylık eğilimlerin dashboard üzerinden izlenmesi gibi bileşenler de sistem kapsamına dahil edilmiştir. Böylece çalışma, makine öğrenmesi modelini kullanıcı odaklı bir web uygulamasıyla bütünleştiren uygulanabilir bir yapı sunmaktadır.

Sonuç olarak bu proje, öğrenci stresini çok değişkenli verilerle tahmin eden, sonuçları anlaşılır biçimde sunan ve zaman içindeki değişimi izlenebilir hâle getiren bir karar destek sistemi tasarlamaktadır. Çalışma, hem yazılım mühendisliği hem de veri temelli karar destek yaklaşımı açısından savunulabilir ve geliştirilebilir bir temel oluşturmaktadır.

Anahtar Kelimeler: öğrenci stresi, makine öğrenmesi, Logistic Regression, karar destek sistemi, web tabanlı sistem

ABSTRACT

This study presents a web-based decision support system designed to estimate university students' stress levels using survey-based and lifestyle-related data. The main problem addressed in this work is that student stress is often monitored only through periodic questionnaires or subjective evaluations, while integrated digital systems that transform multi-dimensional data into meaningful, trackable, and user-oriented outputs remain limited.

Within this scope, the **University Student Stress Dataset** was used to classify students' stress levels into **Low, Medium, and High** categories. During the modeling process, **Logistic Regression, Random Forest, and XGBoost** algorithms were compared, and **Logistic Regression** was selected as the final model based on cross-validation and test performance. To prevent data leakage, the **Stress_Score** variable was excluded from model training, and **Stress_Level** was used as the primary target variable.

The developed system is not limited to generating a classification result. It also includes user registration and login, a stress assessment form, a result screen, short recommendation outputs, storage of previous records, and dashboard-based weekly/monthly trend monitoring. In this way, the study provides a practical structure that integrates a machine learning model with a user-oriented web application.

As a result, this project proposes a decision support system that predicts student stress through multi-variable data, presents the outputs in an understandable way, and makes changes over time trackable. The study provides a defendable and extensible foundation from both software engineering and data-driven decision support perspectives.

Keywords: student stress, machine learning, Logistic Regression, decision support system, web-based system

İÇİNDEKİLER

AKADEMİK DÜRÜSTLÜK BEYANI	i
TEŞEKKÜR	ii
ÖZET	iii
ABSTRACT	iv
İÇİNDEKİLER	v
ŞEKİLLER DİZİNİ	vii
ÇİZELGELER DİZİNİ	viii
KISALTMALAR	ix
1 GİRİŞ	1
1.1 Problem Tanımı	2
1.2 Projenin amacı ve kapsamı	3
1.3 Projenin katkıları	4
2 KAYNAK ARAŞTIRMASI	6
2.1 Üniversite Öğrencilerinde Stresin Yaygınlığı ve Etkileri.....	6
2.2 Öğrenci Stresinin Ölçümünde Kullanılan Yaklaşımlar ve Ölçekler.....	7
2.3 Açık Erişimli Öğrenci Stres Veri Setleri ve Veri Kalitesi	9
2.4 Tabular Veride Makine Öğrenmesi İle Stres Tahmini	11
2.5 Sınıflandırma Modelleri:Logistic Regression,Random Forest ve XGBoost.....	13
2.6 Değerlendirme Metrikleri ve Çok Sınıflı Yaklaşımı	14
2.7 Açıklanabilirlik, Etik ve Veri Gizliliği	16
2.8 Bu Projenin Literatürdeki Konumlandırması	18
3 MATERYAL VE YÖNTEM	20
3.1 Veri Seti: Univesity Student Stress Dataset.....	20
3.1.1 Veri Setinin Özellikleri.....	21
3.1.2 Veri Ön İşleme ve Hedef Değişken Yaklaşımı	23
3.1.3 Veri Bölme Ve Değerlendirme Stratejisi.....	24
3.1.4 Veri Ön İşleme.....	25
3.2 MODEL MİMARİSİ	26
3.2.1 Karşılaştırılan Modeller	27
3.2.2 Nihai Model Olarak Logistic Regression'ın Seçlimesi.....	28
3.2.3 Modelin Sistem İçindeki İşleyişi.....	29

3.2.4	Model Performansının Sınıf Bazlı Değerlendirilmesi.....	29
3.3	Sistem Mimarisi ve Yazılım Bileşenleri	31
3.3.1	Genel Sistem Yapısı.....	31
3.3.2	Arka Uç (Backhend) Katmanı	32
3.3.3	Ön Uç (Frontend) Katmanı	33
3.3.4	Veritabanı ve Veri Yönetimi.....	36
3.3.5	Kullanıcı Akışı ve Bileşenler Arası Etkileşim.....	37
3.4	Gereksinim Analizi.....	40
3.4.1	Fonksiyonel Gereksinimler.....	42
3.4.2	Fonksiyonel Olmayan Gereksinimler.....	43
3.4.3	Gereksinimlerin Proje Kapsamıyla İlişkisi	45
3.5	Veritabanı Tasarımı.	45
3.5.1	Varlıklar ve Tablolar.....	46
3.5.2	Tablolar Arası İlişkiler.....	47
3.5.3	Kullanıcı ve Tahmin Kayıt Yapısı.....	49
3.6	Uygulama Akışı ve Arayüz Yapısı.....	49
3.6.1	Giriş ve Kayıt Akışı.....	50
3.6.2	Stres Değerlendirme Formu Akışı.....	51
3.6.3	Sonuç Ekranı ve Geri Bildirim Yapısı.	51
3.6.4	Dashboard ve Geçmiş Kayıtların Sunumu.	52
4	SONUÇLAR	53
4.1	Veri Bölme Yapısı ve Genel Bulgular	54
4.2	Model Performanslarının Karşılaştırılması.....	55
4.3	Sınıf Bazlı Performansın Değerlendirilmesi	57
4.4	Sistem Çıktıları ve Uygulama Düzeyi Bulguları	58
4.5	Genel Değerlendirme.....	61
5	TARTIŞMA	62
6	İş paketleri ve zamanlama planı.....	64
6.1	Fazlara Göre İş Paketler.....	64
6.2	Ayrıntılı İş Paketi Dağılımı.....	66
6.3	Haftalık Zamanlama ve Gantt Yaklaşımı.....	68
6.4	Planın Proje Yönetimi Açısından Değerlendirilmesi.....	70
7	KAYNAKLAR	71
8	ÖZGEÇMİŞ	73

ŞEKİLLER DİZİNİ

Şekil 3.2 Sistem mimarisi diyagramı	27
Şekil 3.3.5 Kullanıcı akış şeması	38
Şekil 3.3.6 Veri akış diyagramı	39
Şekil 3.4 Use Case diyagramı	41
Şekil 3.5.2 ERD	48
Şekil 3.6 Giriş ekranı görüntüsü	33
Şekil 3.7 Kayıt olma ekranı taslağı	34
Şekil 3.8 Giriş işlemi ekran taslağı	34
Şekil 3.9 Stres değerlendirme formu taslağı	35
Şekil 4.1 Sonuç ekranı taslağı	35
Şekil 4.2 Geçmiş kayıtlar ekranı	36
Şekil 4.1 Stres sınıf dağılım grafiğı	54
Şekil 4.2 Model performans karşılaştırma grafiğı	56
Şekil 4.3 Karışıklık Matrisi	57
Şekil 4.4 Değışken etkisi / önem sıralaması	58
Şekil 4.4 Geliştirilen uygulama form arayüzü	59
Şekil 4.4.2 Geliştirilen uygulama form arayüzü	59
Şekil 4.4.3 Geliştirilen uygulama sonuç arayüzü	60
Şekil 4.4.4 Geliştirilen geçmiş analiz paneli	61

ŞEKİLLER DİZİNİ

Tablo 3.1.1 University Student Stress Dataset veri seti sütunları ve açıklamaları	22
Tablo 3.2.1 Kullanılan modeller, değerlendirme metrikleri ve açıklanabilirlik araçları.....	27
Tablo 3.2.4 Model Performans Karşılaştırması.....	30
Tablo 3.4.1 Fonksiyonel gereksinimler.....	42
Tablo 3.4.2 Fonksiyonel olmayan gereksinimler.....	44
Tablo 3.6.4 Kullanıcı Arayüzü Ekranlarının Rollerini.....	53
Tablo 4.1 Veri Bölme Özeti.....	55
Tablo 4.2 Model Performans Karşılaştırması.....	56
Tablo 4.3 Sınıf Bazlı Sonuçlar (Logistic Regression İçin).....	58
Tablo 4.4 Kullanılabilir ve Test Edilen Senaryolar (UAT).....	62
Tablo 5.1 Proje yaklaşımı, avantajlar ve sınırlılıklar	63
Tablo 6.1 Dönemsel iş paketleri	65
Tablo 6.2 Ayrıntılı iş paketi dağılımı	67
Tablo 6.3 Haftalık zamanlama planı	68

KISALTMALAR

AI	: Artificial Intelligence (Yapay Zekâ)
API	: Application Programming Interface (Uygulama Programlama Arayüzü)
AUC	: Area Under the Curve (Eğri Altında Kalan Alan)
CSV	: Comma-Separated Values (Virgülle Ayrılmış Değerler)
CV	: Cross Validation (Çapraz Doğrulama)
DOM	: Document Object Model (Belge Nesne Modeli)
F1-Score	: F1 Skoru
PR-AUC	: Precision-Recall Area Under the Curve
PSS	: Perceived Stress Scale
ROC-AUC	: Receiver Operating Characteristic – Area Under the Curve
SHAP	: SHapley Additive exPlanations
SSI	: Student-life Stress Inventory
SSI-SM	: Student-life Stress Inventory – Short Form
UAT	: User Acceptance Test (Kullanıcı Kabul Testi)
WHO	: World Health Organization (Dünya Sağlık Örgütü)
XAI	: Explainable Artificial Intelligence (Açıklanabilir Yapay Zekâ)
XGBoost	: Extreme Gradient Boosting

1 GİRİŞ

Üniversite yaşamı, bireylerin akademik, sosyal ve kişisel gelişim süreçlerinin aynı anda yoğunlaştığı bir dönemdir. Bu dönemde öğrenciler; sınavlar, ödevler, zaman yönetimi, ekonomik baskılar, aile beklentileri, sosyal uyum sorunları ve gelecek kaygısı gibi çok boyutlu stres kaynaklarıyla karşı karşıya kalabilmektedir. Dünya Sağlık Örgütü, ergenlik ve genç yetişkinlik döneminde ruh sağlığının bireyin eğitim, işlevsellik ve yaşam kalitesi üzerinde belirleyici olduğunu; 10–19 yaş grubunda her yedi bireyden birinin bir ruhsal bozukluk yaşadığını ve ruh sağlığı sorunlarının eğitim sürecini doğrudan etkileyebildiğini bildirmektedir [7].

Yükseköğretim öğrencileri özelinde yapılan geniş ölçekli çalışmalar da bu kırılganlığı desteklemektedir. Dünya Ruh Sağlığı Araştırmaları kapsamındaki üniversite öğrencileri örnekleminde, öğrencilerin %20,3'ünde son 12 ay içinde en az bir ruhsal bozukluk bulunduğu ve bu öğrencilerin yalnızca %16,4'ünün herhangi bir tedavi aldığı rapor edilmiştir [1]. Bu bulgular, üniversite öğrencilerinin ruhsal yük taşıyan önemli bir grup olduğunu ve mevcut destek mekanizmalarının her zaman yeterli erişimi sağlayamadığını göstermektedir.

Literatür, stresin yalnızca psikolojik iyilik hâlini değil, aynı zamanda akademik performans, uyku düzeni, fiziksel sağlık davranışları ve genel işlevselliği de etkilediğini ortaya koymaktadır. Üniversite öğrencileri üzerinde yapılan sistematik derleme ve meta-analizler, stres ile akademik performans arasında olumsuz ilişkiler bulunduğunu; uyku sorunları, fiziksel aktivite eksikliği ve yaşam tarzı faktörlerinin de bu tabloyu güçlendirebildiğini göstermektedir ([8];[5]). Bu nedenle stresin yalnızca bireysel bir duygu durumu olarak değil, öğrencinin eğitim sürecini ve günlük yaşamını etkileyen çok boyutlu bir durum olarak ele alınması gerekmektedir.

Son yıllarda yapay zekâ ve makine öğrenmesi yöntemleri, eğitim verileri ve anket tabanlı öğrenci verileri üzerinde erken risk tespiti, sınıflandırma ve açıklanabilir analiz üretme açısından dikkat çekici sonuçlar vermeye başlamıştır. Özellikle öğrenci stresinin çok sınıflı yapıda tahmini ve etkileyen değişkenlerin açıklanabilir biçimde gösterilmesi üzerine yapılan güncel çalışmalar, veri temelli karar destek yaklaşımının bu alanda uygulanabilir olduğunu göstermektedir ([10];[11]). Bu bağlamda, üniversite öğrencilerinin stres düzeylerini tahmin eden, geçmiş kayıtlarını izleyen ve anlaşılır öneriler sunan dijital sistemlerin geliştirilmesi hem akademik hem de toplumsal açıdan anlamlı bir ihtiyaç hâline gelmiştir.

1.1 PROBLEM TANIMI

Üniversite öğrencilerinde stresin değerlendirilmesi çoğu zaman öz-bildirim temelli anketler, dönemsel gözlemler veya bireyin kendi farkındalığı üzerinden yürütülmektedir. Bu yöntemler değerli olmakla birlikte, stres düzeyinin süreklilik içinde izlenmesi, farklı risk faktörlerinin birlikte değerlendirilmesi ve sonuçların öğrencinin anlayabileceği biçimde sunulması açısından sınırlılıklar taşımaktadır. Ayrıca ruh sağlığı sorunlarına ilişkin damgalanma, yardım arama davranışındaki çekinceler ve destek hizmetlerine erişimdeki eşitsizlikler, risk altındaki öğrencilerin erken fark edilmesini güçleştirebilmektedir [7]. Üniversite öğrencileri arasında ruhsal sorunların yaygın olmasına rağmen tedaviye başvuru oranlarının düşük kalması da bu boşluğu görünür kılmaktadır [1].

Bir diğer sorun, öğrenci stresinin tek bir nedene indirgenemeyecek kadar çok boyutlu olmasıdır. Akademik yük, sınav sıklığı, ödev yoğunluğu, uyku süresi, fiziksel aktivite, sosyal medya kullanımı, aile desteği, akran baskısı ve kaygı düzeyi gibi değişkenler birbirleriyle etkileşim içinde öğrencinin stres deneyimini şekillendirmektedir. Bu nedenle yalnızca tekil göstergelere bakılarak yapılan yorumlar, öğrencinin gerçek risk profilini yeterince yansıtmayabilir. Sistematik derlemeler, stresin akademik başarıyla ilişkili olduğunu ve özellikle uyku, fiziksel aktivite ve yaşam tarzı değişkenleriyle birlikte değerlendirilmesinin gerekli olduğunu göstermektedir ([8];[5]).

Mevcut dijital çözümlerin önemli bir bölümü ya yalnızca veri toplama işlevi görmekte ya da üretilen veriyi öğrencinin doğrudan yararlanabileceği bir karar destek çıktısına dönüştürmemektedir. Oysa öğrenciye yalnızca ham puan göstermek yerine, veriye dayalı bir stres sınıflandırması sunmak, kısa ve anlaşılır öneriler vermek, ayrıca haftalık ve aylık değişimi izlenebilir hâle getirmek çok daha işlevsel bir yaklaşım sağlayabilir. Güncel çalışmalar, öğrenci stresinin makine öğrenmesi ile çok sınıflı olarak tahmin edilebildiğini ve açıklanabilir yöntemlerle etkili değişkenlerin gösterilebildiğini ortaya koysa da, bu yaklaşımın kullanıcı dostu, web tabanlı ve izlenebilir bir sistem mimarisi içinde ele alınması hâlâ geliştirmeye açık bir alandır ([10];[11]).

Bu çalışmanın ele aldığı temel problem, üniversite öğrencilerinden elde edilen anket ve yaşam alışkanlığı verilerini kullanarak stres düzeyini **düşük, orta ve yüksek** olarak sınıflandıran; sonucu yalnızca teknik bir tahmin olarak bırakmayıp öğrenciye anlaşılır öneriler, kişisel kayıt geçmiş ve zaman içindeki değişimi gösteren grafiksel çıktılar üreten bütünleşik bir web tabanlı sistemin eksikliğidir. Başka bir ifadeyle problem, öğrenci stresine ilişkin çok boyutlu verinin anlamlı, erişilebilir ve sürdürülebilir bir dijital karar destek yapısına dönüştürülememesidir. Bu çalışma, söz konusu boşluğu doldurmak amacıyla makine öğrenmesi destekli, kullanıcı odaklı ve izlenebilir bir stres tahmin sistemi tasarlamayı hedeflemektedir. Ayrıca projede kullanılacak ana veri kaynağı olan University Student Stress Dataset, 3000 lisans öğrencisine ait 18 öznitelik ve hedef etiket olarak Stress_Level alanını içermesi bakımından bu problem alanına doğrudan uygundur.

1.2 PROJENİN AMACI VE KAPSAMI

Bu çalışmanın temel amacı, üniversite öğrencilerine ait anket ve yaşam alışkanlığı verilerini kullanarak öğrencinin stres düzeyini **düşük, orta ve yüksek** olarak sınıflandıran, kullanıcıya kısa ve anlaşılır öneriler sunan, ayrıca geçmiş kayıtları haftalık ve aylık olarak izlenebilir hâle getiren web tabanlı bir karar destek sistemi geliştirmektir. Proje, öğrencinin yalnızca anlık stres durumunu göstermekle sınırlı kalmayıp, zaman içindeki değişimini de görünür kılarak farkındalık oluşturmayı hedeflemektedir. Bu yönüyle sistem, yalnızca veri toplayan pasif bir form yapısından ayrılmakta; tahmin, kayıt, izleme ve temel öneri sunma işlevlerini bir araya getiren bütünleşik bir yapı önermektedir.

Sistemin birincil amaçları şu şekilde sıralanabilir: İlk olarak, kullanıcıdan yaş, cinsiyet, ders çalışma süresi, ders devam durumu, sınav sıklığı, ödev yükü, uyku süresi, fiziksel egzersiz düzeyi, sosyal medya kullanımı, ekran süresi, akran baskısı, aile desteği ve kaygı düzeyi gibi stresle ilişkili değişkenlerin alınması hedeflenmektedir. İkinci olarak, bu değişkenler kullanılarak makine öğrenmesi tabanlı bir model aracılığıyla öğrencinin stres seviyesi **Low, Medium, High** biçiminde sınıflandırılacaktır. Üçüncü olarak, tahmin sonucu yalnızca teknik bir çıktı olarak bırakılmayacak; sistem, her stres düzeyi için önceden tanımlanmış kısa öneri cümleleri üreterek kullanıcıya yorumlanabilir bir geri bildirim sunacaktır. Dördüncü olarak, kullanıcının geçmiş değerlendirmeleri veritabanında saklanacak ve bu kayıtlar haftalık ve aylık grafikler ile tablo görünümünde izlenebilir hâle getirilecektir. Beşinci olarak, sistemin kullanıcı dostu bir web arayüzü ile kayıt olma, giriş yapma, form doldurma, sonuç görüntüleme ve geçmiş tahminleri inceleme işlemlerini desteklemesi amaçlanmaktadır.

Çalışmada kullanılacak temel veri kaynağı, üniversite öğrencilerine ait açık erişimli bir veri setidir. Bu kapsamda ana veri seti olarak `university_student_stress_dataset.csv` dosyası kullanılacaktır. İncelenen veri seti 3000 satır ve 18 sütun içermekte; `Stress_Score` ve hedef etiket olarak `Stress_Level` alanlarını barındırmaktadır. Ayrıca veri setinde yaş, çalışma süresi, sınav sıklığı, ödev yükü, uyku süresi, fiziksel egzersiz, sosyal medya kullanımı, ekran süresi, aile desteği ve akran baskısı gibi proje ile doğrudan ilişkili öznitelikler yer almaktadır. Bu nedenle veri seti, öğrenci stres düzeyinin çok değişkenli biçimde modellenmesi açısından çalışmanın amacıyla uyumludur.

Projenin kapsamı, web tabanlı çalışan ve bireysel kullanıcıyı merkeze alan bir sistem ile sınırlandırılmıştır. Sistemde tek kullanıcı rolü bulunacaktır ve bu rol öğrenci kullanıcısıdır. Yönetici paneli, çoklu rol yönetimi, mobil uygulama, gerçek zamanlı bildirim gönderimi veya büyük dil modeli tabanlı serbest metin üretimi bu çalışmanın kapsamı dışında bırakılmıştır. Benzer şekilde sistem, psikiyatrik ya da klinik teşhis aracı olarak değil; öğrencinin stres farkındalığını artırmayı ve kendi verilerini takip etmesini kolaylaştırmayı amaçlayan destekleyici bir dijital çözüm olarak konumlandırılmaktadır. Bu sınırlama, hem etik çerçeve hem de projenin uygulanabilirliği açısından önem taşımaktadır.

Modelleme tarafında proje, tabular veriye uygun ve bitirme projesi düzeyinde sürdürülebilir yöntemlerle sınırlandırılmıştır. Bu nedenle ilk aşamada Logistic Regression, Random Forest ve XGBoost gibi görece yorumlanabilir ve uygulanabilir sınıflandırma algoritmalarının karşılaştırılması planlanmaktadır. Nihai sistemde ise performans açısından en uygun modelin kullanılması hedeflenmektedir. Böylece proje, aşırı karmaşık derin öğrenme altyapılarına yönelmeden, veri yapısına uygun ve savunulabilir bir yapay zekâ çözümü sunacaktır.

Özetle bu çalışmanın kapsamı; veri setinin doğrulanması, stres tahmini için uygun model yaklaşımının seçilmesi, kullanıcı gereksinimlerinin analiz edilmesi, sistem mimarisi ve veritabanı tasarımının oluşturulması, web arayüzünün ana akışlarının planlanması ve tüm bu yapının mühendislik dokümantasyonu hâline getirilmesini içermektedir. Sistemin tam ölçekli implementasyonu, model performans karşılaştırmaları, kullanıcı testleri ve nihai ürün değerlendirmeleri ise çalışmanın sonraki aşamalarında ayrıntılandırılacaktır.

1.3 PROJENİN KATKILARI

Bu çalışma, üniversite öğrencilerinin stres düzeylerinin yapay zekâ destekli yöntemlerle tahmin edilmesi alanında teknik, uygulamalı ve kullanıcı odaklı katkılar sunmayı amaçlamaktadır. Projenin temel katkısı, öğrenci stresini yalnızca akademik bir sınıflandırma problemi olarak ele almakla kalmayıp, bu tahmini kullanıcıya doğrudan fayda sağlayacak bir web sistemi içinde anlamlı hâle getirmesidir. Bu yönüyle çalışma, veri analizi, makine öğrenmesi ve yazılım geliştirme süreçlerini tek bir bütünlük yapı içinde bir araya getirmektedir.

Teknik açıdan çalışmanın ilk katkısı, üniversite öğrencilerine ait çok değişkenli anket verilerinin kullanılmasıyla stres düzeyinin **düşük, orta ve yüksek** olmak üzere çok sınıflı biçimde tahmin edilmesidir. Projede yaş, çalışma süresi, sınav sıklığı, ödev yükü, uyku süresi, fiziksel egzersiz, sosyal medya kullanımı, ekran süresi, aile desteği, akran baskısı ve kaygı düzeyi gibi farklı değişkenler birlikte değerlendirilerek öğrenci stresinin tek bir faktöre indirgenemeyeceği

gösterilmektedir. Bu yaklaşım, stresin çok boyutlu doğasını daha gerçekçi biçimde modellemeye olanak sağlamaktadır. Ayrıca çalışmada kullanılan ana veri setinin 3000 kayıt ve 18 sütundan oluşması, projenin veri temelli ve savunulabilir bir altyapı üzerinde kurulmasına katkı sunmaktadır.

Metodolojik açıdan ikinci katkı, tabular veri için uygun olan farklı sınıflandırma modellerinin aynı problem üzerinde karşılaştırmalı olarak değerlendirilmesidir. Çalışmada Logistic Regression, Random Forest ve XGBoost gibi yöntemlerin kullanılması planlanmakta; böylece yalnızca tek bir modele bağlı kalmadan, veri yapısına en uygun yaklaşımın belirlenmesi hedeflenmektedir. Bu durum, projenin deneysel yönünü güçlendirmekte ve bitirme projesi düzeyinde ölçülebilir, karşılaştırılabilir ve raporlanabilir sonuçlar üretmesine imkân tanımaktadır. Özellikle XGBoost ve ağaç tabanlı yöntemlerin tabular veri üzerinde güçlü performans sunabilmesi, bu proje için uygun bir yöntemsel çerçeve sağlamaktadır.

Çalışmanın üçüncü katkısı, yapay zekâ modelini yalnızca arka planda çalışan bir tahmin motoru olarak bırakmayıp, kullanıcı etkileşimi olan bir web tabanlı sistem içinde konumlandırmasıdır. Sistem; kullanıcı kayıt ve giriş yapısı, stres değerlendirme formu, sonuç ekranı, geçmiş tahmin kayıtları, haftalık ve aylık grafiksel izleme alanları gibi bileşenlerden oluşacak şekilde tasarlanmaktadır. Bu yapı, öğrencinin yalnızca tek seferlik bir sonuç görmesini değil, zaman içinde kendi stres eğilimini takip edebilmesini de mümkün kılmaktadır. Böylece proje, klasik veri bilimi çalışmalarında sık görülen “yalnızca model doğruluğu raporlama” yaklaşımının ötesine geçerek, yazılım mühendisliği bakış açısıyla ürünleştirilebilir bir sistem tasarımı sunmaktadır. Güncel çalışmalarda öğrenci stresi tahmini ve açıklanabilir analizler sunulsa da, bunların çoğu doğrudan kullanıcıya yönelik, kayıt tutan ve izlenebilir web sistemleri biçiminde ele alınmamaktadır.

Dördüncü katkı, sistemin kullanıcıya yorumlanabilir geri bildirim sunmasıdır. Bu projede tahmin sonucu yalnızca “Low, Medium, High” etiketi olarak gösterilmeyecek; her sınıf için önceden tanımlanmış kısa öneri cümleleri aracılığıyla öğrenciye anlaşılır bir yönlendirme sağlanacaktır. Böylece sistem, teknik sonucu insan odaklı ve eyleme dönüştürülebilir bir çıktıya dönüştürmektedir. Bu yaklaşım, özellikle yüksek stres düzeyi tespit edilen kullanıcılar için farkındalık oluşturma bakımından önemlidir. Aynı zamanda sistemin klinik teşhis amacı taşımadığı, yalnızca destekleyici ve farkındalık artırıcı bir dijital araç olarak konumlandırıldığı da açık biçimde ortaya konulmaktadır. Bu sınırlama, etik ve veri gizliliği açısından önemli bir katkıdır.

Beşinci katkı, projenin açıklanabilir ve raporlanabilir bir yapay zekâ süreciyle tasarlanmasıdır. Nihai sistemde kullanılacak model seçilirken yalnızca doğruluk oranı değil; precision, recall, F1-score, confusion matrix ve gerekli durumlarda ROC-AUC veya PR-AUC gibi ölçütlerin birlikte değerlendirilmesi planlanmaktadır. Bu yaklaşım, özellikle çok sınıflı sınıflandırma problemlerinde daha güvenilir bir performans analizi yapılmasına katkı sağlayacaktır. Böylece proje, yüzeysel bir “tek metrikle başarı” yaklaşımından uzak durarak daha sistematik bir değerlendirme yapısı önermektedir.

Sonuç olarak bu çalışma; öğrenci stresinin çok değişkenli verilerle modellenmesi, farklı makine öğrenmesi yöntemlerinin karşılaştırılması, tahmin sonucunun kullanıcı dostu bir web arayüzü ile sunulması, geçmiş kayıtların izlenmesi ve kısa önerilerle desteklenen bütünleşik bir sistem tasarımı ortaya koyması bakımından özgün katkılar sunmaktadır. Proje, yalnızca teorik bir veri analizi çalışması değil; aynı zamanda uygulanabilir, genişletilebilir ve öğrencilerin günlük yaşamında kullanılabilecek dijital bir stres farkındalık sistemi olarak konumlandırılmaktadır.

2 KAYNAK ARAŞTIRMASI

2.1 ÜNİVERSİTE ÖĞRENCİLERİNDE STRESİN YAYGINLIĞI VE ETKİLERİ

Üniversite öğrenciliği dönemi, bireyin akademik yük, sosyal uyum, ekonomik baskılar ve gelecek planlaması gibi çok sayıda stres kaynağıyla aynı anda karşı karşıya kaldığı bir yaşam evresidir. Bu nedenle stres, yükseköğretim öğrencileri arasında yalnızca geçici bir duygu durumu olarak değil, akademik performansı, psikolojik iyi oluşu ve günlük işlevselliği etkileyen çok boyutlu bir sorun olarak ele alınmaktadır. Dünya Sağlık Örgütü, ergenlik ve genç yetişkinlik döneminde ruh sağlığının eğitim ve yaşam kalitesi üzerinde belirleyici olduğunu, bu yaş grubunda ruhsal sorunların yaygın olduğunu ve destek hizmetlerine erişimin kritik önem taşıdığını vurgulamaktadır [7].

Üniversite öğrencileri üzerinde yürütülen geniş ölçekli araştırmalar da bu tabloyu desteklemektedir. Dünya Ruh Sağlığı Araştırmaları kapsamında yapılan çok merkezli çalışmada, üniversite öğrencilerinin %20,3'ünde son 12 ay içinde en az bir ruhsal bozukluk bulunduğu, buna karşın bu öğrencilerin yalnızca %16,4'ünün herhangi bir tedavi aldığı bildirilmiştir [1]. Bu bulgular, üniversite öğrencilerinin önemli bir bölümünün ruhsal yük taşıdığını, ancak profesyonel destek alma oranının düşük kaldığını göstermektedir.

Stresin etkileri yalnızca psikolojik alanla sınırlı değildir. Sistemik derleme ve meta-analizler, stresin akademik başarıyla olumsuz ilişki içinde olduğunu; uyku bozuklukları, düşük fiziksel aktivite düzeyi, tükenmişlik, dikkat dağınıklığı ve yaşam doyumunda azalma gibi sonuçlarla birlikte görülebildiğini ortaya koymaktadır. Özellikle üniversite öğrencilerinde uyku kalitesi, yaşam tarzı ve psikolojik yük arasındaki ilişkiyi inceleyen güncel çalışmalar, stresin çok değişkenli ve dinamik bir yapıda değerlendirilmesi gerektiğini göstermektedir ([8];[5];[9]).

Öğrenci stresinin kaynağı da tek boyutlu değildir. Akademik baskı, sınav yoğunluğu, ödev yükü, zaman yönetimi, aile beklentileri, akran baskısı, ekonomik koşullar ve sosyal medya kullanımı gibi etkenler stres düzeyini eş zamanlı olarak etkileyebilmektedir. Bu nedenle yalnızca tek bir belirtiye ya da tek bir soruya bakılarak yapılan değerlendirmeler çoğu zaman yetersiz kalmaktadır. Literatürde stresin, bireysel özellikler ile çevresel koşulların etkileşimi sonucunda ortaya çıkan çok boyutlu bir yapı olduğu ve bu nedenle çok değişkenli veri analizi ile incelenmesinin daha uygun olduğu vurgulanmaktadır.

Bu bağlamda üniversite öğrencilerinde stresin erken fark edilmesi ve izlenmesi önemli bir ihtiyaç olarak öne çıkmaktadır. Ancak mevcut uygulamalarda öğrencinin stres düzeyi çoğu zaman yalnızca dönemsel anketlerle ya da öznel değerlendirmelerle belirlenmektedir. Bu durum, zaman içindeki değişimin düzenli biçimde izlenmesini ve riskli eğilimlerin erken fark edilmesini zorlaştırmaktadır. Dolayısıyla öğrenci verilerini sistematik biçimde analiz eden, stres düzeyini sınıflandıran ve kullanıcıya anlaşılır geri bildirim sağlayan dijital sistemlerin geliştirilmesi, hem akademik başarı hem de öğrenci iyi oluşu açısından anlamlı bir araştırma alanı oluşturmaktadır.

2.2 ÖĞRENCİ STRESİNİN ÖLÇÜMÜNDE KULLANILAN YAKLAŞIMLAR VE ÖLÇEKLER

Üniversite öğrencilerinde stresin değerlendirilmesi, literatürde çoğunlukla öz-bildirim temelli psikometrik ölçekler, anket formları ve davranışsal/yaşam tarzı göstergelerinin birlikte kullanılmasıyla gerçekleştirilmektedir. Bu yaklaşımın temel nedeni, stresin doğrudan tek bir fizyolojik belirteçle ölçülemeyen; bireyin çevresel talepleri nasıl algıladığı, bu taleplere nasıl tepki verdiği ve günlük yaşamında bunlardan ne ölçüde etkilendiğiyle ilişkili çok boyutlu bir yapı olmasıdır. Bu nedenle stres araştırmalarında yalnızca tek bir soru ya da tek bir belirtiye dayalı değerlendirmeler yerine, güvenilirliği ve geçerliliği test edilmiş ölçekler tercih edilmektedir.

Bu alanda en yaygın kullanılan araçlardan biri **Perceived Stress Scale (PSS)**'dir. [4] tarafından geliştirilen bu ölçek, bireyin son dönemde yaşamındaki olayları ne ölçüde stres verici, kontrol edilemez ve bunaltıcı algıladığını değerlendirmek amacıyla oluşturulmuştur. PSS, özellikle stresin nesnel olaylardan çok öznel algı boyutunu ölçmesi nedeniyle, farklı yaş gruplarında ve üniversite öğrencileri üzerinde sıkça kullanılmaktadır. Ölçeğin kısa ve uygulanabilir yapısı, araştırmalarda ve tarama amaçlı çalışmalarda tercih edilmesini kolaylaştırmaktadır. Bununla birlikte PSS, stresin genel algılanan düzeyini ölçmekte; akademik yaşam, sınav baskısı veya üniversiteye özgü çevresel etkenleri doğrudan ayrı ayrı sınıflandırmamaktadır. Bu nedenle bazı çalışmalarda daha öğrenci odaklı ölçeklerle birlikte kullanılmaktadır.

Üniversite öğrencilerine özgü geliştirilen araçlardan biri de **Student-life Stress Inventory (SSI)** ve bunun kısa formu olan **SSI-SM**'dir. Bedewy ve Gabriel tarafından üniversite öğrencileri için geliştirilen bu yapı, stresin yalnızca düzeyini değil; baskı kaynakları, duygusal tepkiler, davranışsal tepkiler ve fizyolojik belirtiler gibi boyutlarını da incelemektedir. Bu yönüyle SSI-SM, akademik çevre içinde ortaya çıkan stres yükünü daha bağlamsal biçimde değerlendirme imkânı sunmaktadır. Özellikle öğrenci popülasyonu üzerinde uygulanabilir olması, stres araştırmalarında hedef gruba daha yakın bir ölçüm çerçevesi sağlamaktadır. Ancak bu tür ölçekler de çoğunlukla tek zamanlı ölçüm sunduğu için öğrencinin zaman içindeki değişimini izleme konusunda sınırlı kalabilmektedir.

Stres ölçümünde bir diğer yaklaşım, psikometrik ölçeklerin yaşam tarzı ve davranışsal değişkenlerle birlikte ele alınmasıdır. Son yıllarda yapılan çalışmalar, üniversite öğrencilerinde stresin yalnızca algılanan psikolojik yükü değil; uyku süresi, ders çalışma süresi, sınav yoğunluğu, fiziksel aktivite düzeyi, sosyal medya kullanımı, aile desteği ve akran baskısı gibi değişkenlerle de ilişkili olduğunu göstermektedir. Bu nedenle özellikle makine öğrenmesi temelli çalışmalarda, geleneksel ölçek puanları ile birlikte çok sayıda sosyo-demografik ve davranışsal değişkenin kullanılması yaygınlaşmıştır. Bu yaklaşım, stresin daha geniş bir risk profili içinde modellenmesini mümkün kılmaktadır.

Bununla birlikte yalnızca öz-bildirim anketlerine dayalı yöntemlerin bazı sınırlılıkları vardır. Katılımcının o andaki ruh hâli, sosyal beklentiye uygun yanıt verme eğilimi, soruları farklı yorumlaması ya da kendi durumunu olduğundan az veya fazla bildirmesi, ölçüm doğruluğunu etkileyebilmektedir. Ayrıca tek seferlik uygulanan ölçekler, öğrencinin stres düzeyindeki haftalık veya aylık değişimi yakalamakta yetersiz kalabilmektedir. Bu nedenle güncel araştırmalarda, anket verilerini dijital sistemlerde saklayıp tekrar eden ölçümlerle zaman serisi mantığında izleyebilmek daha anlamlı görülmektedir. Özellikle öğrenciye geçmiş verilerini grafiksel olarak gösteren sistemler, yalnızca ölçüm yapmakla kalmayıp öz-farkındalığı da artırabilmektedir.

Bu çalışmada benimsenen yaklaşım, geleneksel psikometrik ölçek mantığını tamamen dışlamak yerine, onun veri toplama mantığını tabular veri modeline uyarlayan daha uygulanabilir bir sistem kurmaktır. Projede kullanılacak veri setinde yaş, çalışma süresi, sınav sıklığı, ödev yükü, uyku süresi, fiziksel egzersiz, ekran süresi, sosyal medya kullanımı, aile desteği ve akran baskısı gibi çoklu değişkenler yer almakta; hedef çıktı ise stres düzeyinin sınıfsal biçimde ifade edilmesini sağlayan Stress_Level alanı üzerinden kurulmaktadır. Böylece çalışma, yalnızca psikometrik puan üretmekle yetinmeyen; öğrencinin stres düzeyini çok değişkenli olarak sınıflandıran ve bu sonucu dijital ortamda izlenebilir hâle getiren bir yaklaşım önermektedir. Bu yönüyle proje, literatürdeki geleneksel ölçek temelli değerlendirme ile veri odaklı karar destek yaklaşımı arasında bir köprü kurmaktadır.

2.3 AÇIK ERİŞİMLİ ÖĞRENCİ STRES VERİ SETLERİ VE VERİ KALİTESİ

Makine öğrenmesi tabanlı stres tahmin sistemlerinin başarısı, yalnızca kullanılan algoritmaya değil, aynı zamanda veri setinin kalitesine, kapsamına ve problem alanına uygunluğuna da doğrudan bağlıdır. Özellikle öğrenci stresi gibi çok boyutlu ve öz-bildirim ağırlıklı konularda veri setinin temsil gücü, değişken çeşitliliği ve etiket yapısı kritik öneme sahiptir. Literatürde açık erişimli veri setlerinin artması, bu alandaki çalışmaların çoğalmasını kolaylaştırmış olsa da, veri setlerinin örneklem büyüklüğü, demografik kapsamı, değişken seçimi ve etiket güvenilirliği bakımından önemli farklılıklar gösterdiği görülmektedir. Bu nedenle veri seti seçimi, model kurulumundan önce ele alınması gereken temel metodolojik adımlardan biridir.

Öğrenci stresi çalışmalarında kullanılan açık erişimli veri setlerinin önemli bir kısmı anket veya form tabanlıdır. Bu veri setlerinde yaş, cinsiyet, çalışma süresi, sınav sıklığı, ödev yükü, uyku süresi, fiziksel aktivite, sosyal medya kullanımı, ekran süresi, aile desteği, akran baskısı ve kaygı düzeyi gibi değişkenler yer almakta; hedef değişken ise çoğunlukla stres seviyesi ya da stres puanı biçiminde sunulmaktadır. Bu yapı, özellikle tabular veri üzerinde çalışan sınıflandırma algoritmaları için uygun bir zemin hazırlamaktadır. Ancak veri setlerinin yalnızca açık erişimli olması yeterli değildir; bunların gerçekten öğrenci stresini temsil edecek çeşitlilikte, yeterli örneklem büyüklüğünde ve anlamlı özniteliklerle kurulmuş olması gerekir. Aksi hâlde model teknik olarak çalışsa bile genellenebilir ve güvenilir sonuçlar üretmeyebilir.

Bu çalışmada tercih edilen ana veri seti olan **University Student Stress Dataset**, açık erişimli bir kaynak olarak bu bağlamda uygun bir temel sunmaktadır. Veri seti açıklamasına göre çalışma, 3000 lisans öğrencisinin anonim yanıtlarını içermekte ve öğrenci stres düzeyinin sınıflandırılması amacıyla düzenlenmiştir. Ayrıca veri setinde akademik, yaşam tarzı, sosyal ve psikolojik değişkenlerin bir arada yer alması, stresin tek boyutlu değil çok değişkenli biçimde modellenmesine imkân vermektedir. İncelenen dosyada Age, Study_Hours, Class_Attendance, Exam_Frequency, Assignment_Load, Sleep_Hours, Physical_Exercise, Social_Media_Use, Screen_Time, Peer_Pressure, Family_Support, Anxiety_Level, Stress_Score ve Stress_Level gibi alanların bulunması, veri setinin proje kapsamında geliştirilecek web tabanlı stres tahmin sistemi ile doğrudan uyumlu olduğunu göstermektedir.

Veri kalitesi açısından bakıldığında, bu tür veri setlerinde ilk dikkat edilmesi gereken konulardan biri etiket yapısıdır. Bu projede kullanılan veri setinde hem Stress_Score hem de Stress_Level alanlarının yer alması, veri analizi aşamasında dikkatli olunmasını gerektirmektedir. Çünkü Stress_Level etiketinin, Stress_Score üzerinden türetilmiş olması muhtemeldir. Bu durumda model eğitiminde Stress_Score değişkeninin girdi olarak kullanılması veri sızıntısına

(data leakage) yol açabilir ve modelin gerçekte olduğundan daha yüksek performans göstermesine neden olabilir. Dolayısıyla bu çalışmada Stress_Level ana hedef değişken olarak kabul edilirken, Stress_Score alanının model girdisi olarak kullanılıp kullanılmayacağı veri ön işleme aşamasında dikkatle değerlendirilmelidir. Bu nokta, veri seti seçiminin yalnızca örneklem büyüklüğüyle değil, sütunlar arası ilişkinin doğru yorumlanmasıyla da ilgili olduğunu göstermektedir.

Açık erişimli veri setlerinin bir diğer önemli sınırlılığı temsil sorunudur. Seçilen veri seti Bangladeş'teki kamu, özel ve ulusal üniversitelerde öğrenim gören lisans öğrencilerinden toplanmıştır. Bu durum veri setinin belirli bir öğrenci topluluğunu yansıtmasını sağlasa da, sonuçların tüm ülkelerdeki veya tüm yükseköğretim sistemlerindeki öğrenciler için doğrudan genellenmesini zorlaştırmaktadır. Kültürel yapı, eğitim sistemi, ekonomik koşullar ve sosyal baskılar öğrenci stresini etkileyebileceğinden, tek bir coğrafi bağlamdan toplanan veriler belirli sınırlılıklar taşır. Bu nedenle veri seti proje geliştirmek için güçlü bir temel sunsa da, raporda genelleme sınırlarının açık biçimde belirtilmesi gerekir.

Veri kalitesi bakımından dikkate alınması gereken bir başka boyut da öz-bildirim verisinin doğasıdır. Öğrenciler, kendi kaygı düzeylerini, aile desteğini, akran baskısını ya da sosyal medya kullanımını öznel olarak bildirdikleri için yanıtlar algısal farklılıklar içerebilir. Ayrıca bazı kullanıcılar sosyal beklentiye uygun biçimde yanıt verme eğiliminde olabilir. Buna rağmen açık erişimli anket verileri, özellikle stres gibi öznel deneyimlerin modellenmesinde hâlen en erişilebilir ve uygulanabilir veri kaynaklarından biridir. Bu nedenle önemli olan, verinin sınırlılıklarını kabul ederek uygun modelleme stratejileri geliştirmek ve elde edilen sonuçları bu bağlam içinde yorumlamaktır.

Sonuç olarak açık erişimli öğrenci stres veri setleri, makine öğrenmesi tabanlı karar destek sistemleri geliştirmek için önemli fırsatlar sunmaktadır; ancak bu veri setlerinin seçimi ve kullanımı sırasında örneklem büyüklüğü, değişken çeşitliliği, etiket güvenilirliği, veri sızıntısı riski ve temsil gücü dikkatle değerlendirilmelidir. Bu çalışmada kullanılan University Student Stress Dataset, proje amacıyla yüksek düzeyde uyumlu ve uygulanabilir bir temel sunmaktadır. Bununla birlikte veri ön işleme, özellik seçimi ve değerlendirme aşamalarında veri kalitesine ilişkin bu sınırlılıkların dikkate alınması, sistemin daha güvenilir ve savunulabilir biçimde geliştirilmesine katkı sağlayacaktır.

2.4 TABULAR VERİDE MAKİNE ÖĞRENMESİ İLE STRES TAHMİNİ

Öğrenci stresinin makine öğrenmesi ile tahmin edilmesinde kullanılan veri yapıları genel olarak iki ana gruba ayrılmaktadır: fizyolojik sensör verileri ve anket/tablo tabanlı öz-bildirim verileri. Fizyolojik veriler, kalp atım hızı, giyilebilir sensör çıktıları veya pasif izleme verileri gibi kaynaklardan elde edilebilmekte; ancak bu tür yaklaşımlar çoğu zaman daha yüksek maliyet, daha karmaşık veri toplama süreci ve uygulama açısından daha fazla teknik altyapı gerektirmektedir. Buna karşılık anket ve yaşam alışkanlığı temelli tabular veri yapıları, daha düşük maliyetli, daha erişilebilir ve eğitim ortamlarına daha kolay uyarlanabilir bir çözüm sunmaktadır. Güncel çalışmalar da yükseköğretimde öğrenci stresinin tespiti için pahalı fizyolojik sensörlere dayanmayan, anket tabanlı ve açıklanabilir makine öğrenmesi yaklaşımlarının uygulanabilirliğini desteklemektedir.

Tabular veri ile stres tahmini yaklaşımının temel avantajı, öğrencinin durumunu yalnızca tek bir belirti üzerinden değil, çok sayıda akademik, sosyal ve davranışsal değişkenin birlikte değerlendirilmesiyle modelleyebilmesidir. Yaş, ders çalışma süresi, ders devamı, sınav sıklığı, ödev yükü, uyku süresi, fiziksel aktivite, sosyal medya kullanımı, ekran süresi, aile desteği, akran baskısı ve kaygı düzeyi gibi değişkenler birlikte ele alındığında, stres düzeyinin daha gerçekçi ve çok boyutlu biçimde sınıflandırılması mümkün olmaktadır. Bu nedenle tabular veri, özellikle anket tabanlı öğrenci stres çalışmalarında uygun bir yöntemsel zemin sağlamaktadır. Bu çalışmada kullanılan `university_student_stress_dataset.csv` dosyasının da 3000 kayıt ve 18 sütundan oluşması, ayrıca `Stress_Level` hedef değişkenini doğrudan içermesi bakımından bu yaklaşım ile uyumlu olduğu görülmektedir.

Literatürde tabular veri üzerinde öğrenci stresini tahmin etmeye yönelik farklı makine öğrenmesi yöntemlerinin karşılaştırıldığı çalışmalar bulunmaktadır. Scientific Reports'ta yayımlanan 2025 tarihli bir çalışmada, üniversite öğrencilerinin stres düzeylerini sınıflandırmak amacıyla Logistic Regression, SVM, Decision Tree, Random Forest, Gradient Boosting ve XGBoost gibi altı farklı algoritma kullanılmış; değerlendirme ölçütleri olarak precision, recall, F1-score ve accuracy raporlanmıştır. Aynı çalışmada Random Forest modelinin 0.89 doğruluk ile en yüksek performansı gösterdiği, XGBoost'un 0.87 ve Logistic Regression'ın 0.81 doğruluk ile onu izlediği belirtilmiştir. Çalışma ayrıca açıklanabilirlik için SHAP analizi kullanarak öne çıkan değişkenleri raporlamıştır. Bu bulgular, öğrenci stresi gibi tabular ve çok değişkenli veri yapılarında klasik ve ağaç tabanlı yöntemlerin güçlü sonuçlar verebildiğini göstermektedir.

Benzer biçimde, Frontiers in Psychology’de yayımlanan 2025 tarihli bir çalışmada öğrenci stresinin çok sınıflı tahmini için Logistic Regression, Decision Tree, Random Forest, SVM, KNN, XGBoost, LightGBM, Gradient Boosting ve Extra Tree olmak üzere dokuz farklı algoritma karşılaştırılmıştır. Bu çalışmada Decision Tree modelinin accuracy, precision, recall ve F1-score bakımından en yüksek genel performansı verdiği rapor edilmiştir. Aynı çalışma, düşük, orta ve yüksek stres kategorilerinde farklı algoritmaların sınıfa göre değişen başarılar gösterebildiğini de ortaya koymuştur. Bu durum, öğrenci stresinin çok sınıflı yapısında tek bir algoritmanın her kategori için aynı üstünlüğü göstermeyebileceğini ve model seçiminin veri yapısına göre ampirik olarak yapılması gerektiğini göstermektedir.

Önceki çalışmalar, daha küçük veya özel bağlamlarda da benzer bir eğilim göstermektedir. Üniversite öğrencilerinin algılanan psikolojik ve sosyal stresini makine öğrenmesi ile inceleyen 2023 tarihli bir çalışmada, farklı deney düzenekleri ve hiperparametre optimizasyon yöntemleri karşılaştırılmış; en iyi sonucun yaklaşık 0.805 accuracy ve 0.890 F1-score düzeyinde elde edildiği bildirilmiştir. Aynı çalışma, özellik azaltma ve hiperparametre ayarının model performansını etkileyebildiğini, ancak veri yapısının ve değerlendirme stratejisinin de en az algoritma seçimi kadar belirleyici olduğunu göstermektedir. Bu sonuçlar, öğrenci stresi tahmininde yalnızca algoritma seçimine değil, ön işleme, özellik seçimi ve model değerlendirme tasarımına da dikkat edilmesi gerektiğini ortaya koymaktadır.

Bu bulgular ışığında tabular veride makine öğrenmesi ile stres tahmini, bu proje için hem akademik hem de uygulamalı açıdan uygun bir yaklaşım sunmaktadır. Özellikle web tabanlı bir sistem geliştirilmek istendiğinde, anket tabanlı tabular veri ile çalışan modellerin kurulumu, güncellenmesi ve sonuçlarının kullanıcıya sunulması daha yönetilebilir olmaktadır. Ayrıca bu yaklaşım, öğrencinin stres düzeyini pahalı sensör altyapılarına ihtiyaç duymadan, doğrudan günlük yaşam ve akademik alışkanlık verileri üzerinden değerlendirmeyi mümkün kılmaktadır. Bu nedenle bu çalışmada tabular veriye uygun sınıflandırma yöntemlerinin kullanılması, projenin kapsamı, veri seti yapısı ve uygulanabilirlik hedefi açısından tutarlı bir tercih oluşturmaktadır.

2.5 SINIFLANDIRMA MODELLERİ: LOGISTIC REGRESSION, RANDOM FOREST VE XGBOOST

Öğrenci stresinin tabular veri üzerinden tahmin edilmesinde kullanılacak sınıflandırma modellerinin seçimi, hem veri yapısına uygunluk hem de projenin uygulanabilirliği açısından önem taşımaktadır. Bu çalışmada Logistic Regression, Random Forest ve XGBoost modellerinin tercih edilmesinin temel nedeni, bu yöntemlerin tabular veri üzerinde yaygın olarak kullanılması, çok sınıflı sınıflandırma problemlerine uyarlanabilmesi ve performans ile yorumlanabilirlik arasında dengeli bir çerçeve sunabilmesidir. Ayrıca güncel öğrenci stresi çalışmalarında bu modellerin karşılaştırmalı biçimde kullanıldığı ve anlamlı sonuçlar verdiği görülmektedir.

Logistic Regression, sınıflandırma problemlerinde en sık kullanılan temel yöntemlerden biridir. [6] dokümantasyonunda da belirtildiği üzere bu model, düzenlenilmiş bir logit sınıflandırıcısıdır ve çok sınıflı problemlerde uygun çözücüler ile multinomial loss yapısını optimize edebilmektedir. Bu özellik, düşük, orta ve yüksek stres olmak üzere üç sınıflı bir problemde Logistic Regression'ı güçlü bir başlangıç modeli hâline getirmektedir. Modelin görece sade yapısı, eğitim sürecinin hızlı olması ve sonuçların yorumlanmasının diğer karmaşık yöntemlere göre daha kolay olması nedeniyle, bu proje kapsamında baseline model olarak değerlendirilmesi uygundur. Bununla birlikte Logistic Regression, değişkenler arasındaki karmaşık doğrusal olmayan ilişkileri modellemede ağaç tabanlı yöntemler kadar güçlü olmayabilir.

Random Forest, çok sayıda karar ağacının bir araya getirilmesiyle çalışan topluluk öğrenmesi yaklaşımıdır. [5] tanımına göre rastgele ormanlar, her ağacın rastgelelik içeren bir örnekleme ve özellik seçimi süreciyle kurulduğu, ardından bu ağaçların birlikte tahmin ürettiği bir yapı sunmaktadır. Bu yaklaşım, özellikle gürültülü verilerde ve çok değişkenli sınıflandırma problemlerinde tek bir karar ağacına göre daha kararlı sonuçlar elde edilmesine yardımcı olmaktadır. Tabular veri üzerinde farklı türde değişkenleri birlikte değerlendirebilmesi, doğrusal olmayan ilişkileri yakalayabilmesi ve değişken önemlerini incelemeye imkân vermesi nedeniyle Random Forest, öğrenci stresi gibi çok boyutlu verilerde güçlü bir aday modeldir. Bununla birlikte ağaç sayısı arttıkça model karmaşıklığı ve hesaplama maliyeti de yükselmektedir.

XGBoost ise gradyan artırmalı ağaç tabanlı yöntemlerin ölçeklenebilir ve yüksek performanslı bir uygulaması olarak literatürde önemli bir yer edinmiştir. [2] tarafından sunulan XGBoost sistemi, sparsity-aware algoritmalar, yaklaşık ağaç öğrenimi ve sistem seviyesinde optimizasyonlar sayesinde büyük veri ve karmaşık örüntüler üzerinde etkili sonuçlar verebilmektedir. Tabular veri problemlerinde XGBoost'un güçlü performans göstermesi, değişkenler arasındaki karmaşık ilişkileri modelleyebilmesi ve düzenleme mekanizmalarıyla

aşırı öğrenmeyi daha kontrollü yönetebilmesi, bu projede neden aday modeller arasında yer aldığını açıklamaktadır. Özellikle öğrenci stresinin çok sayıda davranışsal ve sosyal değişkenle ilişkili olması, XGBoost gibi esnek karar sınırları kurabilen yöntemleri değerli kılmaktadır. Ancak hiperparametre ayarı, Logistic Regression’a kıyasla daha karmaşıktır ve yanlış ayarlarda modelin aşırı uyum göstermesi mümkündür.

Güncel öğrenci stresi literatürü de bu üç modelin karşılaştırmalı kullanımını desteklemektedir. *Frontiers in Psychology*’de yayımlanan güncel bir çalışmada dokuz farklı makine öğrenmesi algoritması karşılaştırılmış; Logistic Regression ve ağaç tabanlı yöntemler aynı değerlendirme seti içinde ele alınmıştır. *Scientific Reports*’ta yayımlanan bir başka çalışmada ise öğrenci stresinin tahmini için Logistic Regression, Random Forest, Gradient Boosting ve XGBoost gibi yöntemler kullanılmış ve açıklanabilir yapay zekâ analizi ile model çıktıları yorumlanmıştır. Bu bulgular, öğrenci stresinin sınıflandırılması probleminde doğrusal yöntemlerin, bagging temelli topluluk yöntemlerinin ve boosting temelli modellerin birlikte değerlendirilmesinin yerinde bir yaklaşım olduğunu göstermektedir.

Bu proje kapsamında söz konusu üç modelin birlikte ele alınmasının temel amacı, yalnızca en yüksek doğruluğu veren modeli bulmak değildir. Aynı zamanda veri yapısına hangi yaklaşımın daha uygun olduğunu görmek, basit ve yorumlanabilir bir model ile daha karmaşık ve yüksek performanslı modeller arasında karşılaştırma yapmak ve nihai sistem için dengeli bir seçim yapabilmektir. Bu nedenle Logistic Regression temel karşılaştırma modeli, Random Forest güçlü bir topluluk öğrenmesi adayı ve XGBoost ise yüksek performanslı geliştirilmiş boosting yaklaşımı olarak değerlendirilmiştir. Böylece proje, hem akademik olarak savunulabilir hem de uygulama açısından sürdürülebilir bir model seçim süreci ortaya koymaktadır.

2.6 DEĞERLENDİRME METRİKLERİ VE ÇOK SINIFLI SINIFLANDIRMA YAKLAŞIMI

Makine öğrenmesi tabanlı sınıflandırma problemlerinde model başarısının yalnızca tek bir ölçütle değerlendirilmesi çoğu zaman yeterli değildir. Özellikle öğrenci stresi gibi **düşük, orta ve yüksek** olmak üzere birden fazla sınıf içeren problemlerde, modelin her sınıf üzerindeki davranışını ayrı ayrı görebilmek için birden çok metriğin birlikte kullanılması gerekmektedir. Bu nedenle bu çalışmada model performansının değerlendirilmesinde accuracy, precision, recall, F1-score ve confusion matrix gibi temel sınıflandırma ölçütlerinden yararlanılması planlanmaktadır. [6] dokümantasyonunda precision, recall ve F-score’un çok sınıflı problemlerde her sınıf için ayrı ayrı hesaplanabildiği ve ardından micro, macro veya weighted ortalama ile özetlenebildiği belirtilmektedir.

Accuracy, doğru tahmin edilen örneklerin toplam örnek sayısına oranını verdiği için ilk bakışta anlaşılır ve pratik bir ölçüttür. Ancak sınıflar arasında dengesizlik bulunduğunda accuracy tek başına yanıltıcı olabilir. Bir model çoğunluk sınıfını iyi tahmin edip az örnekli sınıflarda zayıf kalsa bile yüksek doğruluk değeri verebilir. Bu nedenle precision, recall ve F1-score gibi ölçütlerin birlikte değerlendirilmesi daha sağlıklı bir yaklaşım sunmaktadır. Precision, modelin pozitif olarak etiketlediği örneklerin ne kadarının gerçekten doğru olduğunu; recall ise ilgili sınıfa ait örneklerin ne kadarını yakalayabildiğini göstermektedir. F1-score ise precision ve recall'un harmonik ortalaması olarak bu iki ölçüt arasında dengeli bir değerlendirme sunmaktadır.

Çok sınıflı sınıflandırma problemlerinde metriklerin nasıl ortalandığı da önemlidir. [6] dokümantasyonuna göre **macro average**, her sınıfı eşit ağırlıkla değerlendirerek sınıf dengesizliğini göz ardı eden ortalamayı; **weighted average** ise her sınıfı kendi destek sayısı kadar ağırlıklandıran ortalamayı ifade etmektedir. Bu nedenle macro average, az örnekli sınıflardaki performansı görünür kılmak açısından değerlidir; weighted average ise genel veri dağılımını daha fazla yansıtır. Bu projede düşük, orta ve yüksek stres sınıflarının her biri önemli olduğundan, yalnızca weighted ortalama ile yetinmek yerine sınıf bazlı skorların ve macro average değerlerinin de raporlanması daha uygun olacaktır.

Confusion matrix, modelin hangi sınıfları birbiriyle karıştırdığını görmeyi sağlayan temel araçlardan biridir. Bu matris yapısında satırlar gerçek sınıfları, sütunlar ise tahmin edilen sınıfları göstermektedir. Böylece örneğin modelin “orta stres” örneklerini ne ölçüde “yüksek stres” olarak etiketlediği veya “düşük stres” sınıfında ne kadar hata yaptığı açık biçimde görülebilir. Özellikle öğrenci stresi gibi komşu sınıflar arasında geçişin doğal olduğu problemlerde confusion matrix, modelin yalnızca ne kadar doğru olduğunu değil, **nerelerde yanlış olduğunu** anlamak açısından son derece değerlidir. Bu nedenle çalışmada her model için confusion matrix oluşturulması planlanmaktadır.

ROC-AUC ve PR-AUC gibi eşik bağımsız ölçütler de model değerlendirmesinde destekleyici rol oynayabilir. [6] dokümantasyonunda ROC AUC skorunun binary, multiclass ve multilabel problemlerde kullanılabildiği, çok sınıflı durumda uygun parametrelerle hesaplanabildiği belirtilmektedir. Bununla birlikte dengesiz veri yapılarında precision-recall eğrilerinin ve buna bağlı ölçütlerin daha bilgilendirici olabileceği literatürde özellikle vurgulanmıştır. Saito ve Rehmsmeier, dengesiz veri kümelerinde precision-recall eğrilerinin ROC eğrilerine göre daha anlamlı yorumlar sağlayabildiğini göstermiştir. Bu nedenle bu projede ana değerlendirme yapısı accuracy, precision, recall, F1-score ve confusion matrix üzerine kurulacak; ROC-AUC veya gerekirse PR-AUC ise destekleyici metrik olarak ele alınacaktır.

Bu çalışmanın problem yapısı, çok sınıflı sınıflandırma çerçevesinde ele alınmaktadır. Yani model, öğrencinin stres düzeyini yalnızca “var/yok” biçiminde değil; **Low, Medium, High** sınıfları üzerinden tahmin edecektir. Bu yaklaşım, öğrencinin durumunu daha ayrıntılı ve anlamlı biçimde ifade etme avantajı sağlamaktadır. Aynı zamanda web tabanlı sistemde kullanıcıya yalnızca risk varlığı değil, riskin düzeyi hakkında da geri bildirim verilmesini mümkün kılmaktadır. Ancak çok sınıflı yapı, model değerlendirmesini de daha dikkatli yürütmeyi gerektirir. Çünkü modelin her üç sınıfta aynı performansı göstermemesi mümkündür. Bu nedenle sınıf bazlı metriklerin raporlanması ve model seçiminin yalnızca tek bir genel skora göre yapılmaması bu proje açısından kritik öneme sahiptir.

Sonuç olarak bu projede benimsenen değerlendirme yaklaşımı, model başarısını çok yönlü olarak incelemeyi hedeflemektedir. Accuracy tek başına yeterli görülmeyecek; precision, recall, F1-score, confusion matrix ve gerekli durumlarda ROC-AUC ya da PR-AUC gibi ölçütlerle daha kapsamlı bir performans analizi yapılacaktır. Böylece seçilecek nihai modelin yalnızca yüksek genel başarı göstermesi değil, aynı zamanda düşük, orta ve yüksek stres sınıfları arasında dengeli ve güvenilir tahminler üretebilmesi esas alınacaktır. Bu yaklaşım, projenin akademik savunulabilirliğini artırdığı gibi, geliştirilecek web sisteminin kullanıcıya daha tutarlı sonuçlar sunmasına da katkı sağlayacaktır.

2.7 AÇIKLANABİLİRLİK, ETİK VE VERİ GİZLİLİĞİ

Yapay zekâ tabanlı sistemlerin eğitim ve sağlıkla ilişkili alanlarda kullanımı arttıkça, yalnızca model doğruluğu değil, kararların ne ölçüde anlaşılabilirliği, veri toplama sürecinin ne kadar meşru olduğu ve birey haklarının ne ölçüde korunduğu da temel değerlendirme ölçütleri hâline gelmiştir. Açıklanabilir yapay zekâyâ ilişkin derlemeler, özellikle hassas karar alanlarında kara kutu modellerin güven ve kabul sorunları doğurduğunu; modelin neden belirli bir çıktıya ulaştığını açıklayabilen yöntemlerin ise kullanıcı güveni ve denetlenebilirlik açısından önemli olduğunu göstermektedir. Eğitim alanındaki açıklanabilir yapay zekâ çalışmaları da benzer biçimde, şeffaflığın yalnızca teknik bir özellik değil; adalet, hesap verebilirlik ve etik kullanım için gerekli bir bileşen olduğunu vurgulamaktadır.

Bu proje bağlamında açıklanabilirlik, modelin verdiği stres tahmininin kullanıcı ve geliştirici tarafından yorumlanabilir olmasını ifade etmektedir. Öğrencinin stres düzeyini etkileyen değişkenlerin yalnızca tahmin motoru içinde gizli kalması yerine, hangi faktörlerin daha etkili olduğunun görülebilmesi sistemin güvenilirliğini artıracaktır. Özellikle tabular veri ile

alıřan modellerde zellik nemleri, karar aęacı tabanlı yaklařımların deęiřken katkıları veya SHAP benzeri yntemler, modelin hangi girdilere daha fazla aęırlık verdięini incelemek iin kullanılabilir. Bu tr aıklamalar, ęrencinin sistem sonucunu yalnızca bir etiket olarak grmesini engelleyip sonucun hangi yařam ve akademik deęiřkenlerle iliřkili olduęunu anlamasına yardımcı olabilir. Gncel ęrenci stresi alıřmalarında da yorumlanabilir ve aıklanabilir modellerin, pahalı ve opak sistemlere gre daha uygulanabilir olduęu zellikle vurgulanmaktadır.

Etik aıdan bakıldıęında, ęrenci stresini tahmin eden bir sistemin dikkatli bir ereve iinde konumlandırılması gerekmektedir. Dnya Saęlık rgt, ergenlik ve gen yetiřkinlik dnemindeki ruh saęlıęı sorunlarının sıklıkla tanınmadan ve tedavi edilmeden kaldıęını; damgalanma, sosyal dıřlanma ve yardım arama davranıřındaki ekincelerin bu sreci zorlařtırabildięini belirtmektedir. Bu nedenle ęrenci stresine iliřkin dijital sistemler geliřtirilirken, kullanıcıyı damgalayan, etiketleyen veya kesin teřhis veriyormuř gibi davranan bir dil yerine; farkındalık artıran, destekleyici ve sınırlılıklarını aıka belirten bir yaklařım benimsenmelidir. Bu alıřmada geliřtirilecek sistem, klinik teřhis aracı olarak deęil, kullanıcıya kendi verisini izleme ve stres dzeyi hakkında destekleyici geri bildirim alma imknı sunan bir karar destek sistemi olarak konumlandırılmaktadır.

Veri gizlilięi boyutunda ise Trkiye’deki hukuki ereve doęrudan dikkate alınmalıdır. Kiřisel Verileri Koruma Kurumu’na gre kiřisel veri, kimlięi belirli veya belirlenebilir gerek kiřiye iliřkin her trl bilgidir; saęlık verileri ise zel nitelikli kiřisel veri kapsamında daha gl koruma gerektirmektedir. Aynı kurumun aıklamalarında kiřisel verilerin iřlenmesinde hukuka ve drstlk kurallarına uygunluk, belirli ve meřru amalarla iřleme, amala baęlantılı, sınırlı ve ll olma ve gerekli sre kadar saklama gibi genel ilkeler aıka belirtilmektedir. Ayrıca veri sorumlusu, veri toplandıęı anda ilgili kiřiye veri iřleme amaı, hukuki sebep ve hakları konusunda aydınlatmakla ykmldr. Bu nedenle proje kapsamında kullanıcıdan alınacak yař, cinsiyet, kaygı dzeyi, aile desteęi veya stres dzeyi gibi alanlar iřlenirken aık rıza, aydınlatma ykmllę, veri minimizasyonu ve uygun saklama ilkeleri gzetilmelidir.

Bu erevede proje tasarımında yalnızca gerekli deęiřkenlerin toplanması, kullanıcıya neden hangi verinin istendięinin aık biimde sunulması ve verilerin sistemde ama dıřı kullanılmaması temel etik gerekliliklerdir. Ayrıca sistemde kullanıcı hesabı ve gemiř kayıt yapısı bulunduęu iin, verilerin korunması amaıyla kimlik doęrulama, eriřim kontrol ve mmkn olduęunda anonimleřtirme veya sınırlı saklama sresi gibi uygulamaların tasarım ařamasında dikkate alınması gerekir. KVKK mevzuatında da kiřisel verilerin silinmesi, yok edilmesi veya anonim hle getirilmesine iliřkin usullerin ayrıca dzenlenmiř olması, veri yařam dngsnn

yalnızca toplama aşamasında değil, saklama ve imha aşamalarında da önem taşıdığını göstermektedir.

Sonuç olarak açıklanabilirlik, etik ve veri gizliliği bu proje için ikincil değil, sistem tasarımının merkezinde yer alan unsurlardır. Öğrenci stresine ilişkin tahmin üreten bir yapay zekâ sistemi, yalnızca yüksek performans gösterdiği için başarılı kabul edilemez; aynı zamanda anlaşılabilir, adil, sınırlılıklarını bilen ve kişisel verileri koruyan bir yapı sunmalıdır. Bu nedenle bu çalışmada model seçimi, kullanıcıya verilecek geri bildirim dili ve veri işleme süreci birlikte ele alınmakta; teknik başarı ile etik sorumluluk arasında dengeli bir sistem tasarımı hedeflenmektedir.

2.8 BU PROJENİN LİTERATÜRDEKİ KONUMLANDIRMASI

Literatür incelemesi, üniversite öğrencilerinde stresin yaygın, çok boyutlu ve akademik yaşamı doğrudan etkileyen bir sorun olduğunu açık biçimde göstermektedir. Aynı zamanda stresin değerlendirilmesinde psikometrik ölçeklerin, anket temelli veri toplama yaklaşımlarının ve son yıllarda makine öğrenmesi tabanlı sınıflandırma yöntemlerinin giderek daha fazla kullanıldığı görülmektedir. Güncel çalışmalar, özellikle tabular veri üzerinde çalışan Logistic Regression, Random Forest, Decision Tree ve XGBoost gibi algoritmaların öğrenci stres düzeyini tahmin etmede anlamlı sonuçlar verebildiğini ortaya koymaktadır. Bununla birlikte bu çalışmaların önemli bir kısmı ya model performansını raporlamakla sınırlı kalmakta ya da geliştirilen yaklaşımı doğrudan son kullanıcıya yönelik, izlenebilir ve bütünleşik bir sistem tasarımına dönüştürmemektedir.

Bu noktada mevcut çalışmanın literatürdeki ilk konumu, öğrenci stresini yalnızca teorik bir sınıflandırma problemi olarak ele almaması, bunu kullanıcı odaklı bir web sistemi içinde değerlendirmesidir. Literatürde veri seti, model ve performans sonuçları üzerine odaklanan çok sayıda çalışma bulunmasına rağmen; kayıt olma, giriş yapma, form doldurma, geçmiş sonuçları inceleme ve haftalık/aylık değişimi grafiklerle takip etme gibi bileşenleri aynı yapı içinde birleştiren, öğrenciye doğrudan dönüt veren uygulama odaklı çalışmalar daha sınırlı görülmektedir. Bu proje, makine öğrenmesi modelini tek başına bırakmayıp onu yazılım mühendisliği bakış açısıyla ürünleştirilebilir bir sistem mimarisi içine yerleştirmesi bakımından literatürdeki mevcut çalışmalardan ayrılmaktadır.

Projenin ikinci konumlandırma noktası, kullanılan veri yapısı ve problem tanımıyla ilgilidir. Bu çalışmada ana veri kaynağı olarak kullanılan University Student Stress Dataset, 3000 kayıt ve

18 sütundan oluşan, açık erişimli ve doğrudan öğrenci stres düzeyinin sınıflandırılmasına uygun bir veri yapısı sunmaktadır. Veri setinde akademik, yaşam tarzı, sosyal ve psikolojik değişkenlerin birlikte yer alması, projenin stresin çok boyutlu doğasına uygun biçimde tasarlanmasına olanak sağlamaktadır. Bu yönüyle çalışma, yalnızca tekil stres ölçeklerinden elde edilen puanlara dayanmayan; çok değişkenli ve veri odaklı bir değerlendirme yaklaşımı benimsemektedir. Ancak veri setinin belirli bir ülke ve öğrenci grubu üzerinden toplanmış olması, genelleme açısından sınırlılık oluşturduğundan, proje literatürde evrensel değil bağlama duyarlı bir çözüm olarak konumlandırılmaktadır.

Çalışmanın üçüncü konumlandırma boyutu, model seçimi ve değerlendirme yaklaşımına ilişkindir. Öğrenci stresine yönelik güncel araştırmalar, farklı algoritmaların farklı veri kümelerinde değişen başarılar gösterebildiğini ortaya koymaktadır. Bu nedenle bu proje, tek bir yöntemi varsayılan doğru çözüm olarak kabul etmek yerine, Logistic Regression, Random Forest ve XGBoost gibi tabular veri üzerinde güçlü performans gösterebilen modelleri karşılaştırmalı olarak ele almaktadır. Böylece proje, literatürde sık görülen yalnızca tek model üzerinden ilerleme eğiliminden uzaklaşarak daha deneysel ve savunulabilir bir yöntem çerçevesi sunmaktadır. Ayrıca değerlendirme sürecinde accuracy ile yetinmeyip precision, recall, F1-score ve confusion matrix gibi ölçütlerin kullanılması, çalışmanın model başarısını daha dengeli ve çok yönlü biçimde incelemesini sağlamaktadır.

Projenin dördüncü konumu, etik ve açıklanabilirlik boyutunda ortaya çıkmaktadır. Literatürde açıklanabilir yapay zekâya ve kullanıcı güvenine yönelik ilgi artmakla birlikte, öğrenci stresine yönelik sistemlerde bu boyut her zaman ürün tasarımının merkezine yerleştirilmemektedir. Bu çalışmada ise sistem yalnızca sınıflandırma sonucu vermeyi değil, kullanıcıya kısa ve anlaşılır öneriler sunmayı, sonucu destekleyici biçimde yorumlanabilir hâle getirmeyi ve kişisel verilerin işlenmesinde etik sınırları gözetmeyi hedeflemektedir. Ayrıca proje, klinik veya psikiyatrik teşhis aracı gibi değil; öğrencinin öz-farkındalığını artıran, destekleyici ve sınırlılıklarını açıkça bilen dijital bir karar destek sistemi olarak konumlandırılmaktadır. Bu yaklaşım, hem Dünya Sağlık Örgütü'nün gençlerin ruh sağlığına ilişkin hassasiyetleriyle hem de kişisel veri işleme konusunda KVKK çerçevesiyle uyumludur.

Sonuç olarak bu çalışma, literatürdeki mevcut öğrenci stresi araştırmaları ile uygulama odaklı yazılım geliştirme yaklaşımı arasında bir köprü kurmaktadır. Proje; açık erişimli veri seti kullanan, çok sınıflı stres tahmini yapan, modelleri karşılaştırmalı olarak değerlendiren, kullanıcıya öneri ve izleme imkânı sunan, etik ve veri gizliliği boyutunu dikkate alan bütünleşik bir sistem önermesi bakımından mevcut çalışmalara tamamlayıcı bir katkı sunmaktadır. Bu yönüyle çalışma, yalnızca akademik bir modelleme denemesi değil; aynı zamanda gerçek kullanıcı senaryosuna dönüştürülebilir, genişletilebilir ve sürdürülebilir bir öğrenci stres tahmin sistemi tasarımı olarak literatürde konumlandırılmaktadır.

3 MATERYAL VE YÖNTEM

Bu bölümde, “Üniversite Öğrencileri için AI Destekli Stres Tahmin Sistemi” projesinin teknik altyapısını oluşturan veri seti, veri ön işleme süreci, modelleme yaklaşımı ve değerlendirme stratejisi açıklanmaktadır. Çalışmanın amacı, üniversite öğrencilerine ait çok boyutlu anket ve yaşam alışkanlığı verilerini kullanarak öğrencinin stres düzeyini sınıflandırabilen ve bu sonucu web tabanlı bir karar destek sistemi içinde kullanıcıya sunabilen bir yapı geliştirmektir. Bu doğrultuda yöntem bölümü, veri kaynağının niteliğini, hedef değişkenin belirlenme biçimini, model eğitim sürecini ve sistemin temel işleyiş mantığını ortaya koymaktadır.

Bu çalışmada benimsenen yöntem, tabular veri üzerinde çok sınıflı sınıflandırma yaklaşımına dayanmaktadır. Öğrencilerin akademik, sosyal, davranışsal ve psikolojik durumlarını temsil eden değişkenler kullanılarak stres düzeyinin **Düşük / Orta / Yüksek (Low / Medium / High)** olarak tahmin edilmesi hedeflenmiştir. Bu amaçla veri seti üzerinde ön işleme adımları uygulanmış, sınıflandırma algoritmaları karşılaştırılmış ve en uygun model seçilerek web sistemi ile bütünleştirilmiştir. Çalışmanın teknik çerçevesi, veri temelli karar verme mantığını yazılım mühendisliği yaklaşımı ile birleştiren modüler bir sistem yapısına dayanmaktadır. Güncel tablo dosyasında da veri seti, model seçimi, değerlendirme ölçütleri ve iş paketleri bu mantık doğrultusunda yapılandırılmıştır.

Bu bölümde ayrıca veri setinin özellikleri, hedef değişken seçimi, eğitim ve test veri bölmeleri, çapraz doğrulama yaklaşımı ve nihai model seçim süreci ayrıntılı olarak ele alınacaktır. Sistem mimarisi, veri akışı, kullanım senaryoları ve veritabanı ilişkileri ise bölümün ilerleyen kısımlarında diyagramlarla desteklenecektir.

3.1 VERİ SETİ: UNIVERSITY STUDENT STRESS DATASET

Bu çalışmada kullanılan temel veri kaynağı, üniversite öğrencilerinin stres düzeyini belirlemeye yönelik hazırlanmış açık erişimli **University Student Stress Dataset** adlı tabular veri setidir. Proje kapsamında veri setinin .csv formatındaki dosyası olan **university_student_stress_dataset.csv** kullanılmıştır. Söz konusu veri seti, öğrencilerin demografik özellikleri, akademik alışkanlıkları, sosyal çevreleri ve yaşam tarzı göstergeleri ile birlikte stres düzeyini etkileyebilecek çok sayıda değişkeni içermektedir. Bu yönüyle veri seti, yalnızca tek bir belirtiye odaklanmak yerine öğrencinin stresini çok değişkenli bir yapı içinde modellemeye imkân vermektedir. Güncel proje tablolarında da veri setinin 18 sütundan oluştuğu, hedef değişkenin Stress_Level olarak tanımlandığı ve sınıflandırma problemi için uygun biçimde yapılandırıldığı görülmektedir.

University Student Stress Dataset veri setinin tercih edilmesinin temel nedeni, öğrencinin stres düzeyini etkileyebilecek akademik, sosyal, ekonomik ve psikolojik faktörleri birlikte içermesidir. Yaş, ders çalışma süresi, derslere katılım oranı, sınav sıklığı, ödev yükü, uyku süresi, fiziksel egzersiz, sosyal medya kullanımı, ekran süresi, aile desteği, akran baskısı ve kaygı seviyesi gibi çoklu değişkenlerin aynı veri yapısında bulunması, geliştirilecek web tabanlı sistemin kullanıcıdan toplayacağı veriyle doğrudan uyum sağlamaktadır. Böylece model, öğrencinin stres durumunu yalnızca tekil bir ölçüte göre değil, çok yönlü bir risk profili içinde değerlendirebilmektedir.

3.1.1 VERİ SETİNİN ÖZELLİKLERİ

Projede kullanılan **University Student Stress Dataset** veri seti, öğrencilerin stres düzeyini etkileyebilecek çok sayıda değişken içermektedir. Veri setinde yaş, cinsiyet, haftalık ders çalışma süresi, derslere katılım oranı, eğitim tipi, sınav sıklığı, ödev yükü, günlük ortalama uyku süresi, fiziksel egzersiz düzeyi, sosyal medya kullanım süresi, toplam ekran süresi, aile gelir düzeyi, akran baskısı, aile desteği, kaygı düzeyi ve üniversite türü gibi alanlar yer almaktadır. Bu değişkenler öğrencinin yalnızca akademik performansına değil, sosyal çevresine, yaşam düzenine ve psikolojik durumuna ilişkin çok boyutlu bir tablo sunmaktadır. Veri seti ayrıca Stress_Score ve Stress_Level olmak üzere stresle ilişkili iki ayrı alan içermektedir.

Bu yapı, stresin öznel ve çok boyutlu doğasını modelleme açısından önemli bir avantaj sağlamaktadır. Çünkü üniversite öğrencilerinde stres, yalnızca sınav baskısı ya da ödev yoğunluğu ile açıklanabilecek kadar dar bir problem değildir. Uyku kalitesi, fiziksel hareketlilik, sosyal medya kullanımı, aile desteği ve akran baskısı gibi değişkenler de öğrencinin genel stres deneyimini etkileyebilmektedir. Veri setinin söz konusu alanları bir araya getirmesi, çalışmanın literatürde önerilen çok değişkenli stres değerlendirme yaklaşımı ile uyumlu olmasını sağlamaktadır.

Tablo 3.1.1 University Student Stress Dataset veri seti sütunları ve açıklamaları

Sütun Adı	Veri Tipi	Açıklama
Age	Sürekli	Öğrencinin demografik yaş verisi.
Gender	Kategorik	Cinsiyet dağılımı.
Study_Hours	Sürekli	Haftalık ortalama akademik çalışma süresi.
Class_Attendance	Sürekli	Derslere düzenli katılım düzeyi (oran).
Tuition	Kategorik	Eğitim tipi veya burs gereksinim durumu.
Exam_Frequency	Sürekli	Karşılaşılan test ve sınav döngüsü sıklığı.
Assignment_Load	Sürekli	Verilen ödevlerin yarattığı yük (skor).
Sleep_Hours	Sürekli	Rapora geçirilen günlük ortalama uyku faktörü.
Physical_Exercise	Sürekli	Haftalık sportif aktivite seviyesi.
Social_Media_Use	Sürekli	Akıllı cihaz vb. kaynaklı sosyal medya kullanım dozu.
Screen_Time	Sürekli	Tüm cihazlarda harcanan toplam dijital ekran süresi.
Family_Income_Level	Kategorik	Ailenin ortalama sosyoekonomik seviyesi.
Peer_Pressure	Sürekli	Öğrencinin hissettiği akademik dışı akran baskısı derecesi.
Family_Support	Sürekli	Çevresel/Ailesel destek ve iletişim kalitesi.

Anxiety_Level	Sürekli	Psikometrik olarak test esnasında beyan edilmiş anksiyete (kaygı) ölçütü.
University_Type	Kategorik	Öğrenim kurumu statüsü.
Stress_Score	Sürekli	Gözlemsel veya nicel test skoru (Hedef değişken "Stress_Level" ile aynı örüntüyü taşıdığından veri sızıntısını -data leakage- önlemek adına eğitim sürecine dahil edilmez).
Stress_Level	Kategorik (Hedef)	Modellerin tahmin etmeye çalıştığı sınıflandırma hedefi. Düşük / Orta / Yüksek (Low / Medium / High) sınıflarını içerir.

3.1.2 VERİ ÖN İŞLEME VE HEDEF DEĞİŞKEN YAKLAŞIMI

Makine öğrenmesi sürecinde en kritik aşamalardan biri, model eğitime dahil edilecek değişkenlerin doğru seçilmesi ve veri yapısının hedef probleme uygun biçimde düzenlenmesidir. Bu çalışmada hedef değişken olarak Stress_Level alanı esas alınmıştır. Bu alan öğrencinin stres düzeyini **Düşük / Orta / Yüksek (Low / Medium / High)** biçiminde sınıflandırmaktadır ve modelin tahmin etmeye çalıştığı temel çıktı değişkenidir. Sürekli bir değer yerine sınıfsal çıktı tercih edilmesi, hem çok sınıflı sınıflandırma probleminin kurulmasını kolaylaştırmakta hem de web sisteminde sonuçların kullanıcıya daha anlaşılır biçimde sunulmasına olanak sağlamaktadır. Güncel fonksiyonel gereksinimlerde de sistemin kullanıcıya doğrudan sınıf çıktısı üretmesi ve buna bağlı kısa öneri sunması hedeflenmiştir.

Veri ön işleme sürecinde özel dikkat gerektiren alan Stress_Score değişkenidir. Bu alan nicel bir stres skorunu temsil etmekte; ancak hedef değişken olan Stress_Level ile aynı örüntüyü taşıdığı değerlendirilmektedir. Bu nedenle Stress_Score'un model girdileri arasında kullanılması veri sızıntısına yol açabilecek ve modelin gerçekte olduğundan daha yüksek performans göstermesine neden olabilecektir. Bu riskten kaçınmak amacıyla proje kapsamında Stress_Score destekleyici bir analiz alanı olarak ele alınmış, fakat model eğitime dahil edilmemiştir. Bu

tercih, sınıflandırma modelinin hedef etiketi dolaylı biçimde ezberlemesini önlemek ve daha güvenilir bir performans değerlendirmesi sağlamak açısından önem taşımaktadır.

Ayrıca veri setindeki kategorik alanların uygun biçimde kodlanması, sayısal değişkenlerin model eğitime hazır hâle getirilmesi ve eğitim sürecinde kullanılacak sütunların standartlaştırılması da yöntemsel çerçevenin bir parçasıdır. Böylece model, kullanıcıdan gelen form verileri ile veri setindeki öznitelikler arasında tutarlı bir ilişki kurabilecek şekilde yapılandırılmaktadır. Bu yaklaşım, hem eğitim aşamasında hem de gerçek zamanlı tahmin sürecinde veri bütünlüğünü korumaya yardımcı olmaktadır.

3.1.3 VERİ BÖLME VE DEĞERLENDİRME STRATEJİSİ

Modelin yalnızca eğitim verisine uyum sağlayan bir yapı üretmemesi, daha önce görmediği örnekler üzerinde de tutarlı sonuçlar verebilmesi gerekmektedir. Bu nedenle proje kapsamında veri seti eğitim ve test olmak üzere iki ana alt kümeye ayrılmıştır. Güncel tablo yapısında veri setinin %80'lik bölümü eğitim verisi, %20'lik bölümü ise test verisi olarak tanımlanmıştır. Eğitim verisi, modelin veri içindeki örüntüleri öğrenmesini sağlarken; test verisi modelin genellenebilirliğini ölçmek için kullanılmaktadır. Bu yaklaşım, sınıflandırma algoritmalarının yalnızca ezbere dayalı değil, yeni örnekler üzerinde de anlamlı sonuçlar üretilip üretilmediğini değerlendirmek açısından standart ve uygun bir yöntemdir.

Bunun yanında model performansının farklı veri parçalarında da kararlı kalıp kalmadığını görebilmek amacıyla eğitim kümesi üzerinde **5-Fold Stratified Cross Validation** uygulanmıştır. Stratified yaklaşımın tercih edilmesi, hedef sınıfların veri alt kümelerinde mümkün olduğunca benzer dağılımda korunmasını sağlamaktadır. Bu yöntem, özellikle çok sınıflı sınıflandırma problemlerinde sınıf dengesizliğinin model yorumunu bozmasını önlemek açısından önemlidir. Böylece yalnızca tek bir eğitim/test bölmesinden elde edilen sonuca bağlı kalınmamış, modelin daha istikrarlı performans gösterip göstermediği de sınanmıştır.

Değerlendirme sürecinde temel başarı ölçütü olarak **Macro F1-Score** benimsenmiştir. Bunun nedeni, düşük, orta ve yüksek stres sınıflarının her birinin ayrı önem taşıması ve genel doğruluk oranının tek başına yeterli yorum imkânı sunmamasıdır. Accuracy metriği de değerlendirme kapsamında kullanılmış; ancak nihai model kararı yalnızca doğruluk oranına göre verilmemiştir. Güncel model performans tablosunda Logistic Regression modelinin çapraz doğrulama ve test sonuçlarında en yüksek dengeyi sunduğu, Random Forest ve XGBoost

modellerine göre daha kararlı bir yapı gösterdiği görülmektedir. Bu nedenle Logistic Regression, projede nihai model olarak seçilmiş ve sistemin karar verici bileşeni olarak konumlandırılmıştır.

3.1.4 VERİ ÖN İŞLEME

Makine öğrenmesi sürecinde güvenilir ve tutarlı sonuçlar elde edebilmek için veri setinin model eğitime uygun biçimde hazırlanması gerekmektedir. Bu çalışmada veri ön işleme süreci, ham veri yapısının sınıflandırma problemine uygun hâle getirilmesi amacıyla gerçekleştirilmiştir. Öncelikle veri setindeki sütunlar incelenmiş, hedef değişken ile doğrudan aynı örüntüyü taşıyan veya veri sızıntısına yol açabilecek alanlar belirlenmiştir. Bu kapsamda Stress_Scoredeğişkeni, hedef değişken olan Stress_Level ile güçlü biçimde ilişkili olduğu için model girdilerinden çıkarılmıştır. Böylece modelin hedef sınıfı dolaylı biçimde ezberlemesinin önüne geçilmeye çalışılmıştır. Bu tercih, değerlendirme sonuçlarının daha gerçekçi ve akademik olarak daha savunulabilir olmasını sağlamaktadır.

Veri ön işleme sürecinin ikinci aşamasında, model eğitime dahil edilecek değişkenler veri tiplerine göre düzenlenmiştir. Gender, Tuition, Family_Income_Level ve University_Type gibi kategorik değişkenler, makine öğrenmesi algoritmalarının işleyebileceği sayısal biçime dönüştürülmüştür. Sayısal değişkenler ise veri setindeki anlamını koruyacak şekilde modele aktarılmıştır. Böylece veri matrisi, sınıflandırma algoritmalarının eğitim sürecine doğrudan verilebilecek standart bir yapıya kavuşturulmuştur. Bu aşama, özellikle farklı veri tiplerini aynı modelleme hattı içinde birlikte kullanabilmek açısından önem taşımaktadır.

Bir diğer önemli adım, veri kalitesinin kontrol edilmesidir. Bu doğrultuda eksik değer, tutarsız kayıt ve sütun bazlı uyumsuzluk kontrolleri yapılmış; eğitim sürecini bozabilecek kayıtlar gözden geçirilmiştir. Veri setinin bütünlüğünü korumak, modelin kararlılığını artırmak ve test aşamasında beklenmedik hataların önüne geçmek açısından bu kontroller gerekli görülmüştür. Özellikle web tabanlı sisteme daha sonra girilecek kullanıcı verilerinin de aynı mantıkla işlenebilmesi için, eğitimde kullanılan veri yapısının temiz ve tutarlı olması temel ön koşullardan biridir.

Veri ön işleme sürecinde ayrıca modelleme aşamasında kullanılacak nihai öznitelik kümesi belirlenmiştir. Bu aşamada öğrencinin stres düzeyini etkileyebilecek akademik, davranışsal, sosyal ve psikolojik değişkenler korunmuş; hedef değişkenle aynı bilgiyi taşıyan veya sınıflandırma sonucunu yapay biçimde yükseltebilecek alanlar dışarıda bırakılmıştır. Böylece model, kullanıcıdan alınan gerçek girdiler üzerinden tahmin yapacak şekilde yapılandırılmıştır.

Bu yaklaşım, geliştirilen sistemin gerçek kullanım senaryolarına daha yakın çalışmasını sağlamaktadır.


Sonuç olarak veri ön işleme süreci; veri setinin temizlenmesi, hedef değişkenin netleştirilmesi, veri sızıntısı riskinin azaltılması, kategorik alanların dönüştürülmesi ve eğitim için uygun veri matrisinin oluşturulması adımlarından oluşmaktadır. Bu adımların her biri, yalnızca model başarısını artırmak için değil, aynı zamanda geliştirilen stres tahmin sisteminin teknik güvenilirliğini ve akademik tutarlılığını sağlamak için de kritik öneme sahiptir. Bu nedenle veri ön işleme, çalışmanın yalnızca teknik bir hazırlık aşaması değil; modelleme kalitesini doğrudan belirleyen temel yöntem bileşenlerinden biri olarak değerlendirilmiştir.

3.2 MODEL MİMARİSİ

Bu çalışmada model mimarisi, üniversite öğrencilerine ait çok değişkenli tabular veriler üzerinden stres düzeyini sınıflandıracak şekilde tasarlanmıştır. Kullanılan veri yapısı, öğrencinin akademik, sosyal, davranışsal ve psikolojik durumunu temsil eden birden fazla öz niteliği aynı anda içermektedir. Bu nedenle modelleme yaklaşımı, tabular veri üzerinde etkili sonuç verebilen ve çok sınıflı sınıflandırma problemlerine uyarlanabilen algoritmalar üzerinden kurulmuştur. Çalışma kapsamında farklı sınıflandırma modelleri karşılaştırmalı olarak değerlendirilmiş; doğruluk, makro F1 skoru ve kararlılık bakımından en uygun sonuç veren model nihai sistemde kullanılmak üzere seçilmiştir. Güncel proje tablolarına göre bu karşılaştırma sürecinde Logistic Regression, Random Forest ve XGBoost modelleri değerlendirilmiş, en dengeli ve kararlı sonuçlar Logistic Regression modeli ile elde edilmiştir.

Model mimarisi yalnızca eğitim sürecindeki algoritmayı ifade etmemektedir. Aynı zamanda kullanıcıdan alınan verinin işlenmesi, uygun biçimde modele aktarılması, tahmin sonucunun yorumlanması ve bu sonucun web arayüzü üzerinden kullanıcıya sunulması da bu mimarinin bir parçasıdır. Bu nedenle sistem, veri toplama katmanı, ön işleme katmanı, sınıflandırma katmanı ve sonuç sunum katmanı olmak üzere birbirini tamamlayan bileşenlerden oluşmaktadır. Kullanıcı tarafından doldurulan stres değerlendirme formu, arka planda uygun veri yapısına dönüştürülmekte; ardından seçilen model üzerinden stres seviyesi tahmin edilmekte ve sonuç kullanıcıya anlaşılır bir biçimde raporlanmaktadır.

Şekil 3.2 Sistem mimarisi diyagramı



3.2.1 KARŞILAŞTIRILAN MODELLER

Çalışmada sınıflandırma problemi için üç farklı model değerlendirilmiştir: Logistic Regression, Random Forest ve XGBoost. Bu modellerin birlikte ele alınmasının temel nedeni, veri yapısına hangi yaklaşımın daha uygun olduğunu deneysel olarak belirleyebilmektir. Logistic Regression, daha sade ve yorumlanabilir bir temel model sunarken; Random Forest ve XGBoost daha karmaşık örüntüleri yakalayabilen alternatif yöntemler olarak değerlendirilmiştir. Bu karşılaştırmalı yaklaşım, tek bir modele bağlı kalmadan daha savunulabilir ve sistematik bir model seçimi yapılmasına olanak tanımaktadır. Güncel tablo yapısında da bu üç modelin aynı problem üzerinde karşılaştırıldığı ve sonuçlarının ayrı ayrı raporlandığı görülmektedir.

Logistic Regression modeli, çok sınıflı sınıflandırma probleminde en yüksek dengeyi sunan yaklaşım olarak öne çıkmıştır. Modelin çapraz doğrulama sonucu ortalama Macro F1 skoru 0.9093, test doğruluğu 0.9083 ve test Macro F1 skoru 0.9036 olarak raporlanmıştır. Bu sonuçlar, aynı veri yapısı üzerinde değerlendirilen diğer modellere göre daha kararlı bir performans elde edildiğini göstermektedir. Random Forest ve XGBoost modelleri de test edilmiş; ancak özellikle kararlılık ve genel denge bakımından Logistic Regression modelinin daha uygun olduğu değerlendirilmiştir. Bu nedenle sistemin nihai karar verici modeli olarak Logistic Regression tercih edilmiştir.

Tablo 3.2.1. Kullanılan modeller, değerlendirme metrikleri ve açıklanabilirlik araçları

Konsept / Algoritma	Amaç ve Beklenti
Logistic Regression	Karşılaştırmalı benchmark testlerinde en yüksek dengeyi sunduğu tespit edilen ve sisteme entegre edilen nihai sınıflandırma modeli.
Random Forest	Gürültülü verilere karşı dayanıklılığı test edilen alternatif karar algoritmaları topluluğu.

XGBoost	Kompleks örüntüleri yakalama hedefiyle test edilen ancak mevcut örneklem boyutunda doğrusal modellere kıyasla aşırı uyum (overfitting) ihtimali barındıran alternatif algoritma.
F1-Score (Macro)	Test verisindeki olası sınıf asimetrisinin (Low / Medium / High) nihai başarı oranını gölgelememesi için esas alınacak ana başarı/değerlendirme ölçütü.
Accuracy	Model sınıflandırmalarının ne ölçüde genel doğru olduğunu ifade eden metrik.
SHAP Analizi (Opsiyonel Özellik)	Özelliklerin (ör: yaş, ekran süresi) stresi ağırlıklı olarak nasıl tetiklediğini yorumlayabilmek adına kurgulanan ve ileriki güncellemeler için planlanan / opsiyonel açıklanabilirlik (XAI) aracı.

3.2.2 NİHAİ MODEL OLARAK LOGISTIC REGRESSION'IN SEÇİLMESİ

Nihai modelin seçiminde yalnızca tek bir başarı ölçütüne bağlı kalınmamıştır. Özellikle çok sınıflı sınıflandırma problemlerinde yalnızca accuracy değerine bakmak, modelin bazı sınıflarda düşük performans göstermesine rağmen genel olarak yüksek görünmesine neden olabilir. Bu nedenle model seçiminde Macro F1 skoru temel ölçüt olarak değerlendirilmiş, bunun yanında test doğruluğu ve sınıf bazlı sonuçlar da dikkate alınmıştır. Güncel model karşılaştırma tablosu incelendiğinde, Logistic Regression modelinin hem çapraz doğrulama hem de test verisi üzerinde en yüksek dengeyi sunduğu görülmektedir. Bu sonuç, modelin yalnızca öğrenme aşamasında değil, daha önce görmediği veriler üzerinde de tutarlı sonuç verdiğini göstermektedir.

Logistic Regression modelinin seçilmesinde bir diğer etken, sistemin web tabanlı ve kullanıcı odaklı yapısına uygun olmasıdır. Daha sade ve yorumlanabilir bir modelin tercih edilmesi, geliştirilen karar destek sisteminin teknik olarak daha şeffaf olmasına katkı sağlamaktadır. Ayrıca daha karmaşık modellerin getirebileceği aşırı uyum riskleri ve yorumlama güçlükleri göz önünde bulundurulduğunda, Logistic Regression'ın bu proje için daha dengeli bir tercih olduğu görülmektedir. Nitekim güncel tablo dosyasında da XGBoost modelinin alternatif ve yüksek potansiyelli bir yaklaşım olarak test edildiği, ancak mevcut örneklem yapısında nihai seçim olarak Logistic Regression'ın öne çıktığı belirtilmiştir.

3.2.3 MODELİN SİSTEM İÇİNDEKİ İŞLEYİŞİ

Geliştirilen sistemde modelin işleyiş mantığı, kullanıcıdan alınan verinin doğrudan sınıflandırma sürecine aktarılması esasına dayanmaktadır. Kullanıcı stres değerlendirme formunu doldurduğunda, girilen bilgiler önce veri yapısına uygun biçimde düzenlenmekte ve modelin beklediği öznitelik sırasına dönüştürülmektedir. Daha sonra bu veri makine öğrenmesi modeline gönderilmekte ve model tarafından Stress_Level hedef değişkenine karşılık gelen sınıf tahmini üretilmektedir. Tahmin sonucu, kullanıcıya doğrudan teknik bir çıktı olarak değil; Düşük, Orta veya Yüksek stres düzeyi biçiminde anlaşılır bir sınıflandırma olarak sunulmaktadır. Buna ek olarak sistem, ilgili sınıfa göre kısa öneriler üretmekte ve geçmiş sonuçlarla birlikte kullanıcı paneline kayıt düşmektedir. Bu yapı, model mimarisinin yalnızca eğitim aşamasında değil, uygulama katmanında da işlevsel ve bütünleşik biçimde kullanıldığını göstermektedir.

Bu yaklaşım, makine öğrenmesi modelinin web sistemiyle tam entegre çalışmasını sağlamaktadır. Kullanıcı arayüzü veri girişini yönetirken, backend katmanı veri doğrulama ve model çağrısını yürütmekte; sonuçlar ise hem ekran üzerinde gösterilmekte hem de daha sonra görüntülenebilmesi için kayıt altına alınmaktadır. Böylece model mimarisi, yalnızca akademik bir algoritma denemesi olmaktan çıkıp, doğrudan çalışan bir karar destek sisteminin çekirdeği hâline gelmektedir.

3.2.4 MODEL PERFORMANSININ SINIF BAZLI DEĞERLENDİRİLMESİ

Seçilen Logistic Regression modelinin başarısı yalnızca genel doğruluk oranı üzerinden değil, her stres sınıfındaki davranışı ayrı ayrı incelenerek değerlendirilmiştir. Çok sınıflı sınıflandırma problemlerinde yalnızca toplam başarı oranına odaklanmak, modelin bazı sınıflarda zayıf kalmasına rağmen genel olarak başarılı görünmesine neden olabilmektedir. Bu nedenle çalışmada model performansı, sınıf bazlı precision, recall ve F1-score değerleri üzerinden de analiz edilmiştir. Bu yaklaşım, özellikle **Düşük / Orta / Yüksek (Low / Medium / High)** stres düzeyleri arasında dengenin sağlanıp sağlanmadığını görmek açısından önem taşımaktadır. Güncel performans tablosuna göre Logistic Regression modeli, karşılaştırılan diğer modellere kıyasla daha istikrarlı ve dengeli sonuçlar üretmiştir.

Sınıf bazlı sonuçlar incelendiğinde, modelin düşük stres sınıfında precision değerinin 0.93, recall değerinin 0.92 ve F1 skorunun 0.92 olduğu görülmektedir. Orta stres sınıfında precision 0.92, recall 0.89 ve F1 skoru 0.90 olarak elde edilmiştir. Yüksek stres sınıfında ise precision 0.82, recall 0.97 ve F1 skoru 0.89 olarak raporlanmıştır. Bu bulgular, modelin özellikle yüksek stres düzeyine sahip öğrencileri yakalama konusunda yüksek duyarlılık gösterdiğini ortaya koymaktadır. Duyarlılığın yüksek olması, sistemin farkındalık oluşturma ve riskli öğrencileri kaçırmama amacı açısından olumlu bir durum olarak değerlendirilmektedir. Öte yandan yüksek stres sınıfındaki precision değerinin diğer sınıflara göre biraz daha düşük olması, modelin bu sınıfta bazı örnekleri yüksek stres olarak tahmin ederken daha temkinli yorumlanması gerektiğini göstermektedir.

Modelin sınıflar arasında yaptığı doğru ve yanlış eşleştirmeleri daha ayrıntılı biçimde incelemek için karışıklık matrisi yaklaşımından yararlanılmıştır. Karışıklık matrisi, modelin hangi sınıfları birbiriyle ne ölçüde karıştırdığını göstermesi bakımından önemli bir analiz aracıdır. Bu çalışmada Logistic Regression modelinin 600 kişilik dış test verisinde değerlendirildiği ve yaklaşık %90.83 doğruluk oranı ile çalıştığı görülmektedir. Karışıklık matrisi sonuçları, modelin düşük ve orta stres sınıflarında genel olarak güçlü bir performans sergilediğini, yüksek stres sınıfında ise güçlü recall değeri sayesinde kritik örnekleri yakalamada etkili olduğunu göstermektedir. Böylece modelin yalnızca genel başarı düzeyi değil, hata dağılımı ve sınıflar arası geçiş davranışı da değerlendirilmiş olmaktadır.

Bu değerlendirme yaklaşımı, seçilen modelin web tabanlı karar destek sistemi içinde kullanılabilirliğini doğrudan desteklemektedir. Çünkü sistemin amacı yalnızca teknik açıdan yüksek doğruluk üretmek değil, aynı zamanda öğrencinin stres düzeyini anlamlı ve güvenilir biçimde sınıflandırmaktır. Özellikle yüksek stres grubundaki kullanıcıların mümkün olduğunca doğru biçimde belirlenmesi, sistemin öğrenci farkındalığını artırma amacıyla uyumlu bir sonuç üretmesini sağlamaktadır. Bu nedenle model performansı, yalnızca tek bir skora indirgenmeden, sınıf bazlı sonuçlar ve karışıklık matrisi ile birlikte değerlendirilmiştir. Bu yaklaşım, çalışmanın hem akademik savunulabilirliğini güçlendirmekte hem de geliştirilen sistemin pratik kullanım değerini artırmaktadır.

Tablo 3.2.4 Model Performans Karşılaştırması

Algoritma / Sınıflandırıcı	Cross-Validation (Ort. Macro F1)	Test Accuracy	Test F1-Score (Macro)	Son Karar
Logistic Regression	0.9093	0.9083	0.9036	Performans Kararlılığı En Yüksek (Seçildi)
Random Forest	0.7748	0.8133	0.7257	Skorları Yetersiz Görüldü
XGBoost	0.8257	0.8733	0.8419	İkinci En Yüksek Model

3.3 SİSTEM MİMARİSİ VE YAZILIM BİLEŞENLERİ

Bu çalışmada geliştirilen sistem, kullanıcıdan veri toplayan, bu verileri makine öğrenmesi modeli ile işleyen ve ortaya çıkan sonucu web tabanlı bir arayüz üzerinden kullanıcıya sunan modüler bir yazılım mimarisi üzerine kurulmuştur. Sistem tasarımı yapılırken hem yazılım mühendisliği ilkeleri hem de projenin pratik kullanımı dikkate alınmıştır. Bu doğrultuda veri toplama, veri işleme, model tahmini, sonuç üretimi ve geçmiş kayıtların saklanması gibi işlevler birbirinden ayrılmış bileşenler üzerinden yapılandırılmıştır. Böylece sistem yalnızca tek seferlik bir tahmin uygulaması değil, aynı zamanda kayıt tutabilen, kullanıcıya geçmiş analizlerini gösterebilen ve karar destek mantığıyla çalışan bütünlük bir yapı hâline getirilmiştir.

Geliştirilen mimaride temel iş akışı şu şekilde işlemektedir: kullanıcı web arayüzü üzerinden sisteme giriş yapmakta, değerlendirme formunu doldurmakta ve bu veriler arka uç sunucusuna iletilmektedir. Sunucu tarafında veri doğrulama ve biçimlendirme işlemleri yapıldıktan sonra ilgili öznitelikler makine öğrenmesi modeline aktarılmakta, model tahmin sonucunu üretmekte ve bu sonuç kullanıcıya anlamlı bir çıktı olarak geri döndürülmektedir. Aynı zamanda tahmin bilgisi ve ilgili meta veriler veritabanına kaydedilerek daha sonra geçmiş ekranı ve gösterge paneli üzerinden yeniden görüntülenebilir hâle getirilmektedir. Güncel tablo ve şekil planında da sistem mimarisinin, veri akışının, kullanıcı akışının ve veritabanı ilişkilerinin ayrı ayrı gösterilmesi öngörülmüştür.

3.3.1 GENEL SİSTEM YAPISI

Sistemin genel yapısı istemci-sunucu mimarisine dayanmaktadır. Kullanıcı tarafında çalışan web arayüzü, öğrencinin sistemle doğrudan etkileşime geçtiği katmanı oluşturmaktadır. Bu katman üzerinden kullanıcı kayıt olabilir, giriş yapabilir, stres değerlendirme formunu doldurabilir, sonuçlarını görüntüleyebilir ve geçmiş analizlerine erişebilir. Arka planda çalışan API sunucusu ise kullanıcıdan gelen istekleri karşılamakta, veri doğrulama işlemlerini yürütmekte, makine öğrenmesi modelini çağırarak ve sonuçları veritabanı ile senkronize etmektedir. Böylece kullanıcı deneyimi ile yapay zekâ bileşeni arasında bir köprü kurulmaktadır.

Bu mimari yaklaşımın temel avantajı, sistem bileşenlerinin birbirinden ayrılarak daha okunabilir, geliştirilebilir ve yönetilebilir bir yapı sunmasıdır. Web arayüzü doğrudan model eğitimiyle ilgilenmez; model de kullanıcı arayüz detaylarını bilmek zorunda kalmaz. Aynı şekilde veritabanı katmanı yalnızca veri saklama ve çağırma görevini yerine getirir. Bu ayırım, hata ayıklama sürecini kolaylaştırmakta ve sistemin ileride daha büyük bir yapıya dönüşmesi durumunda sürdürülebilirlik sağlamaktadır. Güncel plan dosyasında da kullanıcı, arayüz, API sunucusu, model ve veritabanı akışının sistem mimarisi diyagramında ayrı bileşenler olarak gösterilmesi gerektiği belirtilmiştir.

3.3.2 ARKA UÇ (BACKEND) KATMANI

Arka uç katmanı, sistemin veri işleme ve karar üretme merkezini oluşturmaktadır. Bu katmanda kullanıcıdan gelen HTTP istekleri karşılanmakta, kimlik doğrulama işlemleri yürütülmekte, formdan gelen veriler uygun yapıya dönüştürülmekte ve seçilen Logistic Regression modeli üzerinden tahmin sonucu üretilmektedir. Arka uç tarafı aynı zamanda geçmiş kayıtların tutulması, dashboard verilerinin hazırlanması ve kullanıcıya geri dönecek sonuçların yapılandırılması görevlerini de üstlenmektedir. Bu yönüyle backend katmanı yalnızca bir veri iletim aracı değil, sistemin mantıksal işlem merkezidir.


Projede geliştirilen arka uç yapısında kullanıcı işlemleri, tahmin işlemleri ve geçmiş kayıt yönetimi gibi bileşenlerin ayrıştırılması yazılımın bakımını kolaylaştırmaktadır. Kimlik doğrulama ve erişim denetimi, kullanıcıların yalnızca kendilerine ait verilere erişebilmesi açısından önemlidir. Tahmin işlemleri tarafında ise kullanıcıdan alınan verinin modelin beklediği yapıya dönüştürülmesi ve doğru öznitelik sırası ile modele aktarılması gerekmektedir. Bu nedenle backend katmanı, yalnızca veri ileten pasif bir yapı değil; veri bütünlüğünü ve sistem güvenilirliğini sağlayan aktif bir kontrol katmanı olarak değerlendirilmelidir.

3.3.3 ÖN UÇ (FRONTEND) KATMANI


Ön uç katmanı, sistemin kullanıcı ile doğrudan temas eden bileşenlerini kapsamaktadır. Ana sayfa, giriş ve kayıt sayfaları, değerlendirme formu, sonuç ekranı ve gösterge paneli bu katmanın temel parçalarıdır. Kullanıcının sistemden alacağı deneyimin anlaşılır, sade ve yönlendirici olması proje açısından önemli olduğundan, arayüz bileşenleri yalnızca estetik açıdan değil, kullanılabilirlik açısından da tasarlanmıştır. Kullanıcının verileri rahatça girebilmesi, sonucu kolaylıkla yorumlayabilmesi ve geçmiş analizlerini açık biçimde takip edebilmesi hedeflenmiştir. Güncel tablo yapısında da ana sayfa, formlar, değerlendirme ekranı, rapor çıktısı ve dashboard ekranı ayrı rollerle tanımlanmıştır.

Ön uç katmanının bir diğer önemli görevi, modelin teknik çıktısını kullanıcı için anlamlı hâle getirmektir. Makine öğrenmesi modeli arka planda sınıf etiketi üretse de, kullanıcı bunu doğrudan algoritmik bir çıktı olarak değil, açık ve yönlendirici bir sonuç ekranı üzerinden görmelidir. Bu nedenle ön uç tarafında sonuç ekranı, kısa öneriler, renkli durum alanları, grafikler ve geçmiş kayıt tabloları ile desteklenen bir kullanıcı deneyimi kurgulanmıştır. Bu yapı, öğrencinin yalnızca “bir sonuç almakla” kalmayıp kendi stres sürecini takip edebilmesini ve sistemden anlamlı geri bildirim alabilmesini sağlamaktadır.

Şekil 3.6 Giriş ekranı Görüntüsü



Şekil 3.7 Kayıt olma ekranı taslağı



StressTahmin

Ana Sayfa İletişim Giriş **Kayıt Ol**

✨

Kayıt Ol

Ücretsiz hesap oluşturun ve değerlendirmenize başlayın

Ad Soyad

İsmail Can Günay

E-posta

ornek@email.com

Şifre

En az 6 karakter


Şifre Tekrar

Şifrenizi tekrar girin

Kayıt Ol

Zaten hesabınız var mı? [Giriş Yap](#)

Şekil 3.8 Giriş İşlemi Ekran Taslağı



StressTahmin

Ana Sayfa İletişim Giriş **Kayıt Ol**

🔒

Giriş Yap

Hesabınıza giriş yaparak devam edin

E-posta


ornek@email.com

Şifre

Giriş Yap

Hesabınız yok mu? [Kayıt Ol](#)

Şekil 3.9 Stres değerlendirme formu taslağı



StressTahmin

Ana Sayfa İletişim Değerlendirme Dashboard banış yasin şahin Çıkış

1 / 12

Yaş
Şu anki yaşıınız


17 21 35

← Önceki Sonraki →

Şekil 4.1 Sonuç ekranı taslağı



Şekil 4.2 Geçmiş kayıtlar ekranı taslağı



3.3.4 VERİTABANI VE VERİ YÖNETİMİ

Veritabanı katmanı, sistemde üretilen kullanıcı ve tahmin verilerinin güvenli ve düzenli biçimde saklanmasını sağlamaktadır. Kullanıcı bilgileri, değerlendirme formu sonuçları ve geçmiş analiz kayıtları bu katman üzerinden yönetilmektedir. Bu yapı sayesinde kullanıcı sisteme yeniden giriş yaptığında önceki tahmin sonuçlarını görebilmekte ve zaman içindeki değişimini izleyebilmektedir. Veritabanı kullanımı, sistemi tek seferlik çalışan basit bir tahmin aracından çıkarıp kalıcı veri üreten bir karar destek uygulamasına dönüştürmektedir.


Veri yönetimi açısından en önemli noktalardan biri, kullanıcı verisi ile tahmin verisinin birbiriyle ilişkilendirilmesidir. Böylece her tahmin sonucu ilgili kullanıcı hesabına bağlı olarak saklanabilmekte, kullanıcı yalnızca kendi geçmiş verilerine erişebilmektedir. Bu ilişki yapısı, ileride dashboard ekranı üzerinden tarihsel eğilim analizi yapılabilmesini de mümkün kılmaktadır. Güncel şekil planında ERD diyagramının doğrudan bu ilişkileri göstermek için kullanılacağı belirtilmiştir. Bu nedenle veritabanı yapısı, sistemin arka planda çalışan en kritik bileşenlerinden biri olarak değerlendirilmelidir.

3.3.5 KULLANICI AKIŞI VE BİLEŞENLER ARASI ETKİLEŞİM


Sistemdeki kullanıcı akışı, öğrencinin ilk girişten sonuç ekranına ve geçmiş analizlerine kadar olan tüm sürecini kapsamaktadır. Kullanıcı önce sisteme kayıt olmakta veya mevcut hesabıyla giriş yapmaktadır. Daha sonra değerlendirme formunu doldurarak stres tahmin sürecini başlatmaktadır. Arka planda işlenen bu veriler sonucunda sistem kullanıcıya stres düzeyini ve ilgili kısa önerileri göstermektedir. Tahmin verisi aynı zamanda veritabanına kaydedildiği için kullanıcı daha sonra dashboard üzerinden geçmiş sonuçlarını grafiksel biçimde inceleyebilmektedir. Bu akış, sistemin yalnızca tahmin üretmeye değil, aynı zamanda kullanıcı davranışını süreklilik içinde izlemeye yönelik tasarlandığını göstermektedir.

Bileşenler arası etkileşim bakımından bakıldığında, kullanıcı akışının her adımı farklı yazılım parçalarının bir araya gelmesiyle çalışmaktadır. Form ekranı veri toplar, API sunucusu bu veriyi işler, model tahmin üretir, veritabanı kaydı saklar ve arayüz bu çıktıyı kullanıcıya okunabilir hâlde sunar. Bu nedenle sistem mimarisi yalnızca teknik bir dağılım değil, kullanıcı deneyimi ile yazılım bileşenlerinin birbirini desteklediği bütüncül bir süreç olarak değerlendirilmelidir.

Şekil 3.3.5 Kullanıcı akış şeması



Şekil 3.3.6 Veri akış diyagramı




3.4 GEREKSİNİM ANALİZİ

Bir yazılım sisteminin başarılı biçimde geliştirilebilmesi için, sistemden beklenen işlevlerin ve bu işlevleri destekleyen kalite ölçütlerinin açık biçimde tanımlanması gerekmektedir. Bu nedenle gereksinim analizi, çalışmanın yalnızca yazılım tasarımı açısından değil, aynı zamanda proje planlaması ve doğrulama süreci açısından da temel aşamalarından birini oluşturmaktadır. “Üniversite Öğrencileri için AI Destekli Stres Tahmin Sistemi” projesinde gereksinim analizi; öğrencinin sistem üzerinde gerçekleştireceği işlemler, sistemin bu işlemlere vereceği tepkiler, güvenlik ve performans beklentileri ile kullanıcı deneyimine ilişkin temel ilkeler dikkate alınarak hazırlanmıştır. Güncel tablo yapısında da fonksiyonel ve fonksiyonel olmayan gereksinimler ayrı başlıklar altında düzenlenmiş ve proje kapsamıyla uyumlu biçimde yapılandırılmıştır.

Bu çalışmada gereksinimler iki ana grupta ele alınmıştır. Birinci grup, sistemin ne yapacağını tanımlayan **fonksiyonel gereksinimlerdir**. Bu kapsamda kullanıcı kaydı, giriş, stres değerlendirme formunun doldurulması, anlık tahmin üretilmesi, kısa öneri sunulması, geçmiş verilerin grafiksel biçimde görüntülenmesi ve güvenli çıkış işlemi gibi temel işlevler belirlenmiştir. İkinci grup ise sistemin nasıl çalışması gerektiğini tanımlayan **fonksiyonel olmayan gereksinimlerdir**. Bu grupta güvenlik, performans, tasarım kalitesi ve teknik uyumluluk gibi sistemin genel niteliğini belirleyen ölçütler yer almaktadır. Böylece proje, yalnızca çalışan bir yazılım geliştirmeyi değil; aynı zamanda kullanıcı açısından güvenli, hızlı, anlaşılır ve sürdürülebilir bir sistem ortaya koymayı hedeflemektedir.

Şekil 3.4 Use Case diyagramı



3.4.1 FONKSİYONEL GEREKSİNİMLER

Fonksiyonel gereksinimler, sistemin kullanıcıya hangi hizmetleri sunacağını ve bu hizmetlerin nasıl bir iş akışı içinde gerçekleşeceğini ifade etmektedir. Bu proje kapsamında ilk temel gereksinim, kullanıcının sisteme kayıt olabilmesi ve kendi hesabı ile giriş yapabilmesidir. Çünkü stres değerlendirme sonuçlarının kullanıcı bazlı saklanabilmesi ve daha sonra geçmiş analizler üzerinden yeniden görüntülenebilmesi için her öğrencinin sistemde tanımlı bir kullanıcı hesabına sahip olması gerekmektedir. Bu gereksinim, geçmiş veri takibi, kişiselleştirilmiş sonuç sunumu ve dashboard işlevlerinin sürdürülebilmesi açısından temel bir altyapı sunmaktadır. Güncel tabloda da kullanıcı kaydı ve kullanıcı girişi ilk iki temel fonksiyonel gereksinim olarak yer almaktadır.

İkinci temel gereksinim, kullanıcının stres değerlendirme formunu doldurabilmesidir. Bu form, sistemin karar verebilmesi için ihtiyaç duyduğu akademik, sosyal ve davranışsal bilgileri toplamaktadır. Yaş, ekran süresi, uyku düzeni, ödev yükü, sosyal medya kullanımı, akran baskısı ve aile desteği gibi değişkenler bu aşamada kullanıcı tarafından sisteme girilmektedir. Sistem bu verileri yalnızca saklamakla kalmamakta, aynı zamanda seçilen makine öğrenmesi modeli üzerinden işleyerek stres düzeyi tahmini üretmektedir. Bu nedenle form yapısı, sistemin yalnızca kullanıcı arayüzü tarafında değil, modelleme tarafında da kritik bir rol üstlenmektedir. Bu işlev, güncel gereksinim tablosunda “Stres Değerlendirme Formu” ve “Anlık Tahmin İşlemi” başlıkları altında açık biçimde tanımlanmıştır.

Bir diğer önemli gereksinim, sistemin tahmin sonucunu kullanıcıya anlamlı biçimde sunabilmesidir. Bu projede model çıktısı yalnızca teknik bir etiket olarak bırakılmamış; stres seviyesi ile birlikte kısa ve yönlendirici öneriler de kullanıcıya gösterilecek biçimde planlanmıştır. Bu yaklaşım, geliştirilen sistemin salt bir sınıflandırma aracı olmasının ötesine geçerek, kullanıcıya farkındalık kazandıran bir karar destek sistemi niteliği kazanmasını sağlamaktadır. Ayrıca kullanıcının geçmiş analizlerine erişebilmesi ve stres eğilimini grafiksel biçimde izleyebilmesi de sistemin bir diğer temel fonksiyonudur. Bu işlev, kullanıcı paneli ve dashboard ekranı üzerinden gerçekleştirilmektedir. Böylece sistem, yalnızca tek seferlik çıktı üreten bir yapı değil; zaman içinde biriken veriyi anlamlı hale getiren süreklilik taşıyan bir yazılım çözümü sunmaktadır. Güncel tabloda bu gereksinimler “Öneri ve Geri Bildirim” ile “Analiz Gelişim Paneli” başlıkları altında yer almaktadır.

Son olarak sistemin güvenli çıkış işlevini desteklemesi de fonksiyonel gereksinimler arasında değerlendirilmiştir. Oturum kapatma özelliği, kullanıcıya ait verilerin başkaları tarafından görüntülenmesini engellemek ve hesap güvenliğini korumak açısından önemlidir. Özellikle ortak cihaz kullanımı, açık oturum riski ve kullanıcı verilerinin hassas niteliği dikkate alındığında, bu işlev proje için yalnızca teknik bir detay değil; temel güvenlik bileşenlerinden biri olarak görülmelidir. Bu nedenle güvenli çıkış işlemi de sistemin zorunlu işlevlerinden biri olarak tanımlanmıştır.

Tablo 3.4.1 Fonksiyonel gereksinimler

No	Gereksinim Adı	Açıklama
F-01	Kullanıcı Kaydı	Öğrenciler standart kimlik doğrulama bilgileri (e-posta vb.) ile sistemde oturum hesabı açabilmelidir.
F-02	Kullanıcı Girişi	Sistemde ilgili veriler ile güvenilir biçimde oturum açılabilirdir.
F-03	Stres Değerlendirme Formu	Kullanıcı psikososyal faktörlerini (uyku, ekran süresi vb.) forma girebilmelidir.
F-04	Anlık Tahmin İşlemi	Form onaylandığında, uygulama arka planda makine öğrenmesi modelinden yanıt almalı ve tahmin sınıfı (Low / Medium / High) üretmelidir.
F-05	Öneri ve Geri Bildirim	Çıkan sonuca göre yazılım, kişisel refaha yönelik kısa öneriler sunabilmelidir.
F-06	Analiz Gelişim Paneli	Kullanıcı kendi hesabından profilini görüntülediğinde geçmiş stres durumu trendlerini grafik eşliğinde izleyebilmelidir.
F-07	Oturum Kapatma	Güvenli çıkış yapabilme yeteneği sağlanmalıdır.

3.4.2 FONKSİYONEL OLMAYAN GEREKSİNİMLER

Fonksiyonel olmayan gereksinimler, sistemin hangi kalite ölçütleri altında çalışması gerektiğini tanımlamaktadır. Bu gereksinimler doğrudan bir kullanıcı eylemi olarak görünmese de, sistemin güvenilirliği, kabul edilebilirliği ve sürdürülebilirliği açısından en az fonksiyonel gereksinimler kadar önemlidir. Bu çalışmada fonksiyonel olmayan gereksinimler güvenlik, performans, tasarım ve teknik uyumluluk başlıkları altında ele alınmıştır. Özellikle kullanıcı verisi işleyen ve kişisel geçmiş kayıtları tutan bir sistem geliştirildiği için bu kalite boyutlarının açık biçimde tanımlanması zorunlu görülmüştür. Güncel tabloda da bu gereksinimlerin dört temel başlık altında toplandığı görülmektedir.

Güvenlik açısından ilk beklenti, kullanıcı oturumlarının uygun erişim kontrolü ile korunması ve kullanıcı şifrelerinin açık metin olarak saklanmamasıdır. Kullanıcının sisteme kayıt olurken verdiği kimlik bilgileri ve sisteme girdikten sonra oluşturduğu stres değerlendirme geçmişi belirli bir düzeyde kişisel veri niteliği taşıdığı için, oturum güvenliği ve parola güvenliği sistem tasarımının vazgeçilmez unsurları arasındadır. Bu doğrultuda kimlik doğrulama mekanizmasının modern web güvenlik ilkelerine uygun biçimde çalışması, yetkisiz erişimlerin önlenmesi ve parolaların güçlü biçimde saklanması beklenmektedir. Bu gereksinim, projenin yalnızca teknik olarak değil, etik ve veri güvenliği açısından da savunulabilir olmasını desteklemektedir.

Performans boyutunda ise sistemin kullanıcıdan gelen isteklere makul süreler içinde yanıt verebilmesi gerekmektedir. Özellikle form gönderimi sonrasında model tahmininin ve sonuç ekranının kullanıcıyı gereksiz biçimde bekletmemesi önemlidir. Çok uzun süren tahmin işlemleri, kullanıcı deneyimini olumsuz etkileyebileceği gibi sistemin pratik kullanım değerini de azaltacaktır. Bu nedenle API yönlendirmeleri, veri işleme adımları ve tahmin süreci, kullanıcı açısından kabul edilebilir sürelerde tamamlanmalıdır. Güncel tabloda bu beklenti, yapay zekâ servisinin ideal senaryoda birkaç saniye içinde yanıt vermesi şeklinde ifade edilmektedir.

Tasarım ve teknik uyumluluk gereksinimleri de sistemin kullanılabilirliği açısından önem taşımaktadır. Kullanıcı arayüzünün masaüstü ve mobil cihazlarda uyumlu çalışması, sade ve anlaşılır bir tasarım sunması ve tarayıcı tarafında tutarlı görüntülenmesi hedeflenmiştir. Stres değerlendirme sistemi gibi öğrenci odaklı bir uygulamada, kullanıcı arayüzünün karmaşık ve yorucu olmaması; form alanlarının rahat doldurulabilir, sonuç ekranının anlaşılır ve dashboard görünümünün takip edilebilir olması gerekmektedir. Bunun yanı sıra sistemin modern web tarayıcılarında sorunsuz çalışması ve ön uç bileşenlerinin uygun DOM yapısı ile oluşturulması da teknik uyumluluğun temel parçaları arasında yer almaktadır. Bu gereksinimler, yazılımın yalnızca işlevsel olarak değil, kullanım kalitesi bakımından da yeterli bir standartta olmasını sağlamaktadır.

Tablo 3.4.2 Fonksiyonel olmayan gereksinimler

No	Kategori	Gereksinim
NF-01	Güvenlik	Oturum güvenliği HTTP tabanlı modern koruma (HttpOnly vb.) ile sürdürülmeli ve parolalar açık metin (cleartext) olarak depolanmamalı, şifrelenmelidir.
NF-02	Performans	API yönlendirmeleri ve yapay zeka servisi makul süreler içerisinde (ideal senaryoda birkaç saniye) kullanıcıya cevap dönebilmelidir.
NF-03	Tasarım	Kullanıcı arayüzü masaüstü ile mobil boyutlarda uyumlu (responsive) çalışmalı, karmaşadan uzak (clean UI) tutulmalıdır.
NF-04	Teknik Uyumluluk	Geliştirilen sistem modern web tarayıcılarında render edilebilmeli ve projeye dair bileşenler doğru DOM yapısıyla oluşturulmalıdır.

3.4.3 GEREKSİNİMLERİN PROJE KAPSAMIYLA İLİŞKİSİ

Tanımlanan gereksinimler, projenin kapsamı ve hedefleriyle doğrudan ilişkilidir. Bu çalışma, üniversite öğrencilerine yönelik web tabanlı bir stres tahmin ve farkındalık sistemi geliştirmeyi amaçlamaktadır. Bu nedenle gereksinim analizi, ne tür kullanıcı davranışlarının destekleneceğini, hangi verilerin toplanacağını, sistemin hangi sonuçları üreteceğini ve tüm bunların hangi kalite ölçütleri altında gerçekleştirileceğini netleştirmektedir. Gereksinimlerin açık biçimde tanımlanmış olması, hem sonraki tasarım kararlarının gerekçelendirilmesini kolaylaştırmakta hem de geliştirilen sistemin proje hedeflerinden sapmasını önlemektedir.

Ayrıca bu gereksinimler, çalışmanın ilerleyen aşamalarında yapılacak test ve doğrulama faaliyetleri için de bir ölçüt sunmaktadır. Kullanıcı senaryolarının başarılı biçimde gerçekleşmesi, sistemin yalnızca yazılmış olmasıyla değil; önceden belirlenen gereksinimleri karşılayıp karşılamadığıyla değerlendirilecektir. Bu nedenle gereksinim analizi, yazılım geliştirme sürecinin başında yapılan teorik bir tanım olmaktan ziyade, tüm proje boyunca referans alınacak bir kontrol çerçevesi olarak düşünülmelidir. Böylece proje; planlama, tasarım, geliştirme, test ve raporlama aşamalarında tutarlı bir mühendislik çizgisi izleyebilecektir.

3.5 VERİTABANI TASARIMI

Geliştirilen stres tahmin sisteminin yalnızca anlık tahmin üretmesi değil, aynı zamanda kullanıcıya ait geçmiş analizleri saklayabilmesi ve daha sonra yeniden gösterebilmesi için uygun bir veritabanı yapısına ihtiyaç duyulmaktadır. Bu nedenle veritabanı tasarımı, projenin temel teknik bileşenlerinden biri olarak ele alınmıştır. Sistem içinde kullanıcı bilgileri, stres değerlendirme sonuçları ve bu sonuçlarla ilişkili açıklayıcı kayıtlar birbirleriyle tutarlı biçimde saklanmalıdır. Bu yapı, uygulamanın tek seferlik çıktı üreten basit bir form sisteminden çıkıp, geçmiş verileri üzerinde takip ve yorum yapılabilen bir karar destek yapısına dönüşmesini sağlamaktadır.

Veritabanı tasarımı yapılırken sistemin temel işlevleri esas alınmıştır. Kullanıcı kaydı, giriş işlemleri, form verilerinin işlenmesi, tahmin sonucunun saklanması ve geçmiş kayıtların gösterge panelinde görüntülenmesi gibi işlevler, veritabanında uygun tablolar ve ilişkiler kurulmasını gerektirmektedir. Güncel plan dosyasında da ERD'nin zorunlu diyagramlardan biri olarak tanımlanması ve kullanıcı ile tahmin kayıtlarının ilişkilendirileceği bir yapı öngörülmesi, veritabanı tasarımının proje için merkezi bir rol taşıdığını göstermektedir.

3.5.1 VARLIKLAR VE TABLOLAR

Bu proje kapsamında veritabanı yapısının merkezinde kullanıcı bilgileri ve stres değerlendirme kayıtları yer almaktadır. İlk temel varlık **kullanıcı** tablosudur. Bu tabloda öğrencinin sisteme giriş yapabilmesi için gerekli kimlik doğrulama bilgileri ve hesapla ilişkili temel alanlar tutulmaktadır. Kullanıcı hesabı, sistemde yapılan tüm stres analizlerinin belirli bir kişiye bağlanabilmesi için zorunludur. Böylece aynı sistem içinde birden fazla kullanıcı yer alsa bile her kullanıcının geçmiş kayıtları birbirinden ayrılmış olur. Güncel fonksiyonel gereksinim tablosunda kullanıcı kaydı ve kullanıcı girişi temel sistem işlevleri arasında tanımlandığı için, kullanıcı tablosu veritabanı tasarımının ilk ve zorunlu bileşenidir.

İkinci temel varlık **stres değerlendirme** tablosudur. Bu tabloda kullanıcı tarafından forma girilen veriler ile model tarafından üretilen tahmin sonucu birlikte saklanmaktadır. Öğrencinin yaş, ders çalışma süresi, uyku süresi, ekran süresi, akran baskısı, aile desteği ve benzeri alanları bu tablo ile ilişkilendirilebilir. Ayrıca tahmin sonucu olarak üretilen Stress_Level değeri ve ilgili zaman damgası da burada tutulmalıdır. Böylece her değerlendirme, hem kullanıcının o anda girdiği verileri hem de sistemin verdiği çıktıyı tek bir kayıt altında toplamış olur. Bu yapı, geçmiş analizlerin daha sonra grafiksel veya tablo biçiminde gösterilmesine doğrudan katkı sağlamaktadır.

İsteğe bağlı olarak üçüncü bir varlık olarak **öneri** veya **geri bildirim** tablosu da düşünülebilir. Eğer sistemde gösterilen kısa öneriler dinamik biçimde saklanmak istenirse, bu bilgiler ayrı bir tabloda tutulabilir. Ancak proje kapsamı açısından öneri metinleri doğrudan tahmin sonucu ile birlikte değerlendirme kaydına da eklenebilir. Bu nedenle öneri bileşeninin ayrı tablo olarak tasarlanması zorunlu değildir; fakat sistemin ileride genişletilmesi planlanıyorsa ayrı bir yapı tercih edilmesi daha esnek bir tasarım sunabilir. Güncel şekil planında da ERD'nin User, StressAssessment ve Recommendation benzeri ilişkileri gösterecek biçimde hazırlanması öngörülmektedir.


3.5.2 TABLOLAR ARASI İLİŞKİLER

Veritabanı tasarımında en önemli noktalardan biri, tablolar arasındaki ilişkilerin doğru kurulmasıdır. Bu projede temel ilişki, bir kullanıcının birden fazla stres değerlendirme kaydına sahip olabilmesidir. Başka bir ifadeyle, kullanıcı tablosu ile stres değerlendirme tablosu arasında **bire-çok (one-to-many)** ilişki bulunmaktadır. Bu ilişki sayesinde aynı kullanıcı sistem üzerinde farklı tarihlerde birden fazla form doldurabilir ve her bir analiz sonucu ayrı kayıtlar hâlinde saklanabilir. Bu yapı, kullanıcının zaman içindeki stres eğiliminin izlenebilmesi için zorunludur.

Eğer öneri veya geri bildirim bilgisi ayrı bir tabloda tutulacaksa, bu durumda stres değerlendirme kaydı ile öneri kaydı arasında da ilişki kurulması gerekir. Böylece her tahmin sonucuna karşılık gelen açıklayıcı çıktı ayrı biçimde saklanabilir. Ancak proje kapsamı daha sade tutulmak istenirse, öneri metni doğrudan değerlendirme tablosuna alan olarak eklenebilir. Buradaki tasarım kararı, sistemin ne kadar büyütülmek istendiğine göre değişebilir. Bitirme projesi kapsamı açısından sade ve anlaşılır bir yapı tercih edilmesi çoğu zaman daha uygun olacaktır.

Tablolar arası ilişkilerin doğru kurulması, yalnızca verinin saklanması açısından değil, kullanıcıya gösterilecek geçmiş kayıtların ve dashboard grafiklerinin doğru üretilmesi açısından da önemlidir. Çünkü kullanıcı panelinde gösterilecek tüm tarihsel analizler, veritabanındaki bu ilişkilerin düzenli ve tutarlı kurulmasına bağlıdır. Bu nedenle ERD diyagramı, proje dokümantasyonunda yalnızca görsel bir destek unsuru değil; sistem mantığını açıklayan temel tasarım çıktılarından biri olarak değerlendirilmelidir.

Şekil 3.5.2 ERD



3.5.3 KULLANICI VE TAHMİN KAYIT YAPISI

Sistemin kullanıcı odaklı çalışabilmesi için her tahmin sonucunun belirli bir kullanıcı hesabı ile ilişkilendirilmesi gerekmektedir. Bu nedenle kullanıcı ve tahmin kayıt yapısı, proje boyunca verinin nasıl izleneceğini belirleyen temel mekanizmalardan biridir. Kullanıcı sisteme giriş yaptıktan sonra gerçekleştirdiği her değerlendirme kendi hesabı altında saklanmalıdır. Böylece sistem, yalnızca genel sonuç üretmekle kalmaz; aynı zamanda belirli bir öğrencinin geçmiş verilerini zaman sırasına göre yeniden sunabilir. Bu yapı, dashboard ekranında stres eğilimlerinin gösterilmesini mümkün kılan altyapıyı oluşturur.

Kullanıcı ve tahmin kayıt yapısında tutulacak alanların yalnızca gerekli bilgilerle sınırlı olması önemlidir. Kullanıcının kimlik doğrulama bilgileri ayrı tabloda tutulurken, analiz verileri ve tahmin sonuçları ayrı kayıtlar olarak saklanmalıdır. Bu ayrım hem veri düzenini korumakta hem de güvenlik açısından daha uygun bir yapı sunmaktadır. Kullanıcı hesabı ile tahmin kayıtları arasında kurulan ilişki sayesinde, sistemde geçmiş analizlerin listelenmesi, belirli bir tarihteki sonucun çağırılması ve zaman içindeki genel eğilimin grafiklerle gösterilmesi mümkün hâle gelmektedir. Güncel fonksiyonel gereksinimler içinde kullanıcı girişi, analiz gelişim paneli ve geçmiş kayıtların grafiksel olarak gösterilmesi tanımlandığı için, bu kayıt yapısı proje hedefleriyle doğrudan uyumludur.

Veritabanı tasarımında bu kayıt yapısının düzenli kurulması, sistemin ileride geliştirilebilmesi açısından da önem taşımaktadır. Örneğin daha sonra sisteme farklı kullanıcı rolleri, ek istatistik alanları veya daha ayrıntılı rapor yapıları eklenmek istenirse, mevcut kullanıcı-tahmin ilişkisi bu genişlemeyi destekleyen temel iskelet olacaktır. Bu nedenle kullanıcı ve tahmin kayıt yapısı yalnızca mevcut işlevler için değil, projenin ileride büyütülmesi açısından da stratejik bir tasarım unsurudur.

3.6 UYGULAMA AKIŞI VE ARAYÜZ YAPISI

Bu çalışmada geliştirilen sistem yalnızca makine öğrenmesi temelli bir sınıflandırma modeli sunmakla kalmamakta, aynı zamanda bu modelin sonuçlarını kullanıcıya anlamlı ve erişilebilir biçimde ileten bir web arayüzü de sağlamaktadır. Bu nedenle uygulama akışı ve arayüz yapısı, projenin teknik başarısı kadar kullanıcı deneyimi açısından da önemli bir yere sahiptir. Sistem; öğrencinin giriş yapmasından değerlendirme formunu doldurmasına, sonuç ekranını görüntülemesinden geçmiş kayıtlarını incelemesine kadar uzanan bütüncül bir kullanım süreci

üzerine kurulmuştur. Güncel plan dosyasında da ana sayfa, giriş/kayıt ekranları, değerlendirme formu, sonuç ekranı ve dashboard ayrı arayüz bileşenleri olarak tanımlanmıştır.

Uygulama akışı tasarlanırken temel amaç, kullanıcının teknik ayrıntılarla uğraşmadan sistemi rahatça kullanabilmesini sağlamaktır. Bu nedenle arayüz bileşenleri sade, yönlendirici ve anlaşılır olacak şekilde kurgulanmıştır. Kullanıcı hangi veriyi neden girdiğini anlayabilmeli, sistem sonucunu rahatlıkla yorumlayabilmeli ve geçmiş verileri üzerinde genel bir değerlendirme yapabilmelidir. Böylece yapay zekâ modeli arka planda çalışırken, ön yüzde kullanıcıya anlaşılır bir deneyim sunulmaktadır. Bu yapı, geliştirilen sistemin yalnızca teknik bir prototip değil, aynı zamanda kullanılabilir bir web tabanlı karar destek aracı olduğunu göstermektedir.

3.6.1 GİRİŞ VE KAYIT AKIŞI

Sistemin ilk kullanım aşaması, öğrencinin kendi hesabı üzerinden kayıt olması veya mevcut hesabıyla giriş yapmasıdır. Bu yapı, her öğrencinin kendi değerlendirme kayıtlarını yalnızca kendisinin görebilmesi açısından önem taşımaktadır. Kullanıcı sisteme ilk kez geldiğinde kayıt ekranı üzerinden temel kimlik doğrulama bilgilerini girerek hesap oluşturmakta; daha sonra giriş ekranı üzerinden sisteme erişim sağlamaktadır. Bu akış, sistemin kişiye özel veri saklama yapısı ile doğrudan ilişkilidir. Kullanıcı hesabı olmadan geçmiş değerlendirme sonuçlarının belirli bir kişiye bağlanması mümkün olmayacağından, kayıt ve giriş akışı sistemin temel başlangıç noktası olarak kabul edilmektedir. Güncel fonksiyonel gereksinimler içinde kullanıcı kaydı ve kullanıcı girişi ilk iki temel işlev olarak tanımlanmıştır.

Giriş ve kayıt ekranlarının tasarımında kullanıcıyı yormayan, sade ve açık bir yapı hedeflenmiştir. Form alanlarının anlaşılır olması, hatalı girişlerde kullanıcıya uygun geri bildirim verilmesi ve erişim sürecinin olabildiğince akıcı ilerlemesi amaçlanmıştır. Bu sayede kullanıcı sisteme güven duyarak sürece başlayabilmekte ve sonraki değerlendirme aşamasına rahatça geçebilmektedir. Kullanıcının sisteme güvenle erişebilmesi, proje kapsamında tanımlanan güvenlik ve kullanılabilirlik gereksinimleri ile de doğrudan uyumludur.

3.6.2 STRES DEĞERLENDİRME FORMU AKIŞI

Kullanıcı giriş yaptıktan sonra sistemin en önemli bileşenlerinden biri olan stres değerlendirme formuna yönlendirilmektedir. Bu form, öğrencinin stres düzeyini etkileyebilecek akademik, sosyal, davranışsal ve psikolojik değişkenleri toplamaktadır. Kullanıcının yaş, ekran süresi, uyku düzeni, ders çalışma süresi, ödev yükü, sosyal medya kullanımı, aile desteği ve akran baskısı gibi bilgileri sisteme girmesi beklenmektedir. Böylece modelin karar üretmesi için gerekli veri yapısı kullanıcı tarafından sağlanmış olmaktadır. Bu form aynı zamanda veri setindeki sütun yapısı ile sistem arayüzü arasında kurulan en önemli bağıdır. Güncel veri seti tablosunda da Age, Study_Hours, Sleep_Hours, Social_Media_Use, Screen_Time, Peer_Pressure, Family_Support ve Anxiety_Level gibi alanların doğrudan modelleme yapısında kullanıldığı görülmektedir.

Form tasarımı temel amaç, veri giriş sürecini olabildiğince kolaylaştırmaktır. Kullanıcının uzun ve karmaşık alanlarla karşılaşması yerine, anlaşılır başlıklar ve kolay doldurulabilir giriş öğeleri ile sürecin yönetilmesi hedeflenmiştir. Böylece kullanıcıdan veri toplama işlemi daha düzenli, daha hızlı ve hata oranı daha düşük biçimde gerçekleştirilebilmektedir. Formun tamamlanmasının ardından sistem bu verileri backend katmanına göndererek model tahmin sürecini başlatmaktadır. Bu akış, sistemin veri toplama ile karar üretme bileşenleri arasında doğrudan bir köprü görevi görmektedir. Ayrıca formun doğru çalışması, proje kapsamında tanımlanan “Stres Değerlendirme Formu” ve “Anlık Tahmin İşlemi” gereksinimlerinin yerine getirilmesi açısından da belirleyicidir.

3.6.3 SONUÇ EKRANI VE GERİ BİLDİRİM YAPISI

Form gönderildikten sonra sistem, kullanıcı tarafından sağlanan verileri seçilen Logistic Regression modeline iletmekte ve öğrencinin stres düzeyini sınıflandırmaktadır. Bu tahmin sonucunda kullanıcıya Düşük, Orta veya Yüksek stres düzeyi gösterilmektedir. Ancak sistem yalnızca sınıf etiketi döndürmekle sınırlı kalmamaktadır. Tahmin sonucuna göre kullanıcıya kısa ve yönlendirici geri bildirimler sunulmakta, böylece teknik çıktı daha anlaşılır bir kullanıcı deneyimine dönüştürülmektedir. Bu yaklaşım, geliştirilen yapıyı salt bir sınıflandırma aracı olmanın ötesine taşıyarak karar destek niteliği kazandırmaktadır. Güncel gereksinim tablosunda da bu işlev “Öneri ve Geri Bildirim” başlığı altında tanımlanmıştır.

Sonuç ekranının kullanıcı açısından açık, anlaşılır ve yönlendirici olması önemlidir. Kullanıcı bu ekranda yalnızca bir sınıf etiketi görmek yerine, stres düzeyinin ne anlama geldiğini ve buna karşı nasıl bir yaklaşım benimseyebileceğini de anlayabilmelidir. Bu nedenle sonuç ekranı, sınıflandırma çıktısı ile kısa öneri yapısını birleştiren bir arayüz bileşeni olarak değerlendirilmiştir. Ayrıca sonuç verisinin veritabanına kaydedilmesi sayesinde, bu çıktı daha sonra geçmiş ekranı ve dashboard yapısında yeniden kullanılabilir hâle gelmektedir. Seçilen Logistic Regression modelinin test performansı ve sınıf bazlı başarımı da sistem sonucunun güvenilirliğini desteklemektedir.

3.6.4 DASHBOARD VE GEÇMİŞ KAYITLARIN SUNUMU

Sistemin önemli bileşenlerinden biri de kullanıcının önceki tahmin kayıtlarını Bu yapı .inceleyebildiği ve zaman içindeki genel eğilimini görebildiği dashboard yapısıdır geçmiş ,sayesinde kullanıcı yalnızca anlık stres sonucunu görmekle kalmamakta değerlendirmeleri arasında karşılaştırma yapabilmekte ve kendi stres düzeyindeki değişimleri sistemi tek seferlik çalışan basit bir tahmin uygulamasından ayıran ,Bu özellik .izleyebilmektedir Güncel fonksiyonel gereksinimler içinde “Analiz Gelişim Paneli” .en önemli unsurlardan biridir işlevinin doğrudan tanımlanmış olması da bu yapının proje açısından zorunlu bileşenlerden biri olduğunu göstermektedir.

Dashboard ekranında yer alan tablo ve grafik yapıları, veritabanında saklanan geçmiş tahmin kayıtlarının kullanıcıya görsel olarak sunulmasına imkân tanımaktadır. Bu ekran, öğrencinin belirli tarihlerde aldığı sonuçları incelemesini, zaman içindeki eğilimleri yorumlamasını ve sistemle daha sürekli bir etkileşim kurmasını sağlamaktadır. Özellikle tarihsel kayıtların görselleştirilmesi, sistemin farkındalık oluşturma amacını güçlendirmektedir. Bu yönüyle dashboard yalnızca ek bir görsel katman değil, projenin kullanıcı odaklı değer önerisini tamamlayan temel işlevlerden biri olarak değerlendirilmelidir. Güncel şekil listesinde de dashboard arayüzü ve geçmiş analiz paneli final aşaması için ayrı görseller olarak tanımlanmıştır.

Tablo 3.6.4: Kullanıcı Ara Yüzü Ekranlarının Roller

Ekran	Kullanım Amacı	Temel Tasarım Doğası
Ana Sayfa / Tanıtım	Projeyi dış dünyaya tanıtan açılış noktası.	Yönlendirici (Call-to-action) ve temiz tasarım.
Formlar (Giriş / Kayıt)	Verilerin kimliğe tanımlanması ve izole edilmesi.	Veri güvenliği hissiyatı veren yalın giriş elemanları.
Değerlendirme Ekranı	Literatürdeki faktör verilerinin (yaş, aktivite vb.) öğrenci bazlı toplanması.	Okunabilir, kaydırmalı kolay menüler.
Rapor Çıktısı	Makine öğrenmesi tahmini ile kullanıcıya hızlı durum geribildirim yapılması.	Görsel ağırlıklı metin kutuları (örn: yüzdelik stres).
Gelişim (Dashboard)	Veri analiz sonuçlarının geçmiş dönemsel kaydının takip edilmesi.	Dinamik ve tarihsel eğilim grafik (Chart) alanları.


4 SONUÇLAR

Bu bölümde, çalışma kapsamında gerçekleştirilen veri analizi, model karşılaştırması ve sistem geliştirme sürecinden elde edilen temel bulgular sunulmaktadır. Elde edilen sonuçlar, hem seçilen veri setinin problem alanı ile uyumlu olduğunu hem de önerilen makine öğrenmesi yaklaşımının öğrenci stres düzeyinin sınıflandırılmasında uygulanabilir bir temel sunduğunu göstermektedir. Ayrıca geliştirilen web tabanlı sistem yapısının, model çıktılarının kullanıcıya anlamlı ve izlenebilir biçimde sunulmasına uygun bir çerçeve oluşturduğu görülmektedir. Bu yönüyle sonuçlar, projenin teknik ve uygulamalı hedefleri açısından tutarlı bir ilerleme sağlandığını ortaya koymaktadır.

4.1 Veri Bölme Yapısı ve Genel Bulgular

Çalışmada kullanılan **University Student Stress Dataset**, eğitim ve test olmak üzere iki temel parçaya ayrılmış; ayrıca eğitim verisi üzerinde **5-Fold Stratified Cross Validation** uygulanmıştır. Bu yaklaşım, modelin yalnızca belirli bir veri bölmesine bağlı olarak değil, daha dengeli ve güvenilir bir değerlendirme çerçevesi içinde incelenmesini sağlamıştır. Veri bölme stratejisi sonucunda, model karşılaştırmalarının tutarlı biçimde yürütülebileceği uygun bir deneysel yapı oluşturulmuştur. Bu bulgu, proje kapsamında izlenen yöntemsel yaklaşımın veri yapısı açısından uygun olduğunu göstermektedir.

Şekil 4.1 Stres sınıf dağılım grafiği




Tablo 4.1: Veri Bölme Özeti

Alt Küme (Subset) / Teknik	Oran - Yapı	Odak / Gerekçe
Eğitim Verisi (Train Set)	% 80	Sınıflandırma modelinin eldeki yapıları, özellikleri keşfetmesi ve öğrenmesi için.
Test Verisi (Test Set)	% 20	Eğitilen modelin ezber bozup bozmadığını ispat etmek adına tamamen kör test uygulanması için.
Değerlendirme (Cross-Validation)	5-Fold Stratified	Öğrenilen sınıf dengesizliğinin performans kararlılığını ölçmek üzere, eğitim verisi içerisinde "Çapraz Doğrulama" kurgusu.

4.2 Model Performanslarının Karşılaştırılması

Çalışma kapsamında **Logistic Regression**, **Random Forest** ve **XGBoost** algoritmaları karşılaştırılmıştır. Elde edilen sonuçlara göre **Logistic Regression**, çapraz doğrulama ve test performansı bakımından en dengeli sonuçları vermiştir. Özellikle **CV Macro F1 = 0.9093**, **Test Accuracy = 0.9083** ve **Test Macro F1 = 0.9036** değerleri, bu modelin mevcut veri yapısı üzerinde en güçlü aday olduğunu göstermektedir. Buna karşılık Random Forest ve XGBoost modelleri belirli düzeyde başarı göstermiş olsa da, genel performans dengesi açısından Logistic Regression'ın gerisinde kalmıştır. Bu nedenle nihai sistemde kullanılmak üzere en uygun model Logistic Regression olarak belirlenmiştir.

Şekil 4.2 Model performans karşılaştırma grafiği



Tablo 4.2: Model Performans Karşılaştırması

Algoritma / Sınıflandırıcı	Cross-Validation (Ort. Macro F1)	Test Accuracy	Test F1-Score (Macro)	Son Karar
Logistic Regression	0.9093	0.9083	0.9036	Performans Kararlılığı En Yüksek (Seçildi)
Random Forest	0.7748	0.8133	0.7257	Skorları Yetersiz Görüldü
XGBoost	0.8257	0.8733	0.8419	İkinci En Yüksek Model

4.3 Sınıf Bazlı Performansın Değerlendirilmesi

Seçilen Logistic Regression modelinin başarısı yalnızca genel doğruluk oranı üzerinden değil, sınıf bazlı ölçütlerle de değerlendirilmiştir. Sonuçlara göre model, **Low** sınıfında **0.93 precision, 0.92 recall ve 0.92 F1-score**; **Medium** sınıfında **0.92 precision, 0.89 recall ve 0.90 F1-score**; **High** sınıfında ise **0.82 precision, 0.97 recall ve 0.89 F1-score** üretmiştir. Bu bulgular, modelin özellikle yüksek stres düzeyindeki öğrencileri yakalama açısından güçlü bir duyarlılığa sahip olduğunu göstermektedir. Sınıf bazlı sonuçlar birlikte değerlendirildiğinde, modelin üç sınıf arasında kabul edilebilir ve dengeli bir performans sergilediği söylenebilir.

Şekil 4.3 Karışıklık Matrisi

Şekil 4.3. Karışıklık Matrisi

Gerçek Sınıf	Tahmin Edilen Sınıf		
	Yüksek	Düşük	Orta
Yüksek	63	0	2
Düşük	0	228	21
Orta	14	18	254


Tablo 4.3 Sınıf Bazlı Sonuçlar (Logistic Regression İçin)

Sınıf Etiketi	Precision (Hassasiyet)	Recall (Duyarlılık)	F1-Score
Low	0.93	0.92	0.92
Medium	0.92	0.89	0.90
High	0.82	0.97	0.89

4.4 Sistem Çıktıları ve Uygulama Düzeyi Bulguları

Modelleme sürecine ek olarak, sistemin kullanıcıya dönük yapısı da belirli bir olgunluğa ulaşmıştır. Kullanıcı kayıt ve giriş yapısı, stres değerlendirme formu, sonuç ekranı, geçmiş kayıtların tutulması ve dashboard üzerinden eğilimlerin izlenmesi gibi temel bileşenler proje kapsamında yapılandırılmıştır. Böylece model çıktısı yalnızca teknik bir sınıflandırma sonucu olarak bırakılmamış; kullanıcıya anlaşılır, izlenebilir ve yorumlanabilir bir biçimde sunulabilecek bir sistem tasarımı ortaya konmuştur. Ayrıca kullanıcı kabul testi senaryoları açısından değerlendirildiğinde; form doğrulama, giriş denetimi, yetkisiz erişimin engellenmesi ve hata durumlarında kullanıcıya geri bildirim verilmesi gibi temel işlevlerin sistem mantığı içinde karşılandığı görülmektedir.

Şekil 4.4 Değişken etkisi / önem sıralaması




Şekil 4.4 Geliştirilen uygulama form arayüzü

The screenshot shows the first step of a form in the StressTahmin application. The header includes the app name 'StressTahmin' and navigation links: 'Ana Sayfa', 'İletişim', 'Değerlendirme' (highlighted), 'Dashboard', 'barış yasin şahin', and 'Çıkış'. The main content area features a dark blue background with a central card. The card has a birthday cake icon and the title 'Yaş' (Age). Below the title, it asks 'Şu anki yaşıңыз' (Your current age). A horizontal slider is shown with values 17, 21, and 35. The slider is currently set to 21. Below the slider are two buttons: '← Önceki' (Previous) and 'Sonraki →' (Next). At the bottom, there is a progress indicator with a single blue dot.


Şekil 4.4.2 Geliştirilen uygulama form arayüzü

The screenshot shows the eighth step of the form in the StressTahmin application. The header is identical to the previous step. The main content area features a dark blue background with a central card. The card has a smartphone icon and the title 'Günlük Sosyal Medya (saat)' (Daily Social Media (hours)). Below the title, it asks 'Günde kaç saat sosyal medyada vakit geçiriyorsunuz?' (How many hours do you spend on social media per day?). A horizontal slider is shown with values 0, 3, and 12. The slider is currently set to 3. Below the slider are two buttons: '← Önceki' (Previous) and 'Sonraki →' (Next). At the bottom, there is a progress indicator with eight blue dots, the eighth dot being highlighted.

Şekil 4.4.3 Geliştirilen uygulama sonuç arayüzü



Şekil 4.4.4 Geliştirilen geçmiş analiz paneli



Tablo 4.4: Kullanılabilir ve Test Edilen Senaryolar (UAT)

Senaryo Olayı	Test Edilen Durum	Beklenen Çıktı / Kurgu	Test Geri Bildirimi
Form - Geçersiz Veri	Anketin boş bırakılması / hatalı tip gönderilmesi.	Doğrulama uyarılarının devreye girmesi.	Doğrulandı
Giriş Toleransı	Kayıtlı dışı veya eksik deneme işlemi.	İşlem engeli ve kullanıcı uyarısı yapılması.	Doğrulandı
Sayfa Korunumu	Oturum açmamış kimsenin istatistik rotasına (/dashboard) ulaşmaya çalışması.	Yetkisiz tespitinin yapılarak Giriş sayfasına zorunlu sürüklenmesi.	Doğrulandı
Hizmet İstisnası	Çözümlemeyen veya yavaş bir ağ isteğinde uygulamanın tepkisi.	Uygulamanın hatayı yakalayıp sonsuz yüklemekten kaçınarak haber veren mesaj (popup/yazı) basması.	İşlevsel/ Doğrulandı

4.5 Genel Değerlendirme

Bu bölümde sunulan sonuçlar birlikte değerlendirildiğinde, proje kapsamında izlenen veri odaklı yaklaşımın teknik açıdan anlamlı ve savunulabilir çıktılar ürettiği görülmektedir. Veri setinin problem alanına uygunluğu, model karşılaştırmalarının sistematik biçimde yürütülmesi ve Logistic Regression modelinin dengeli performans göstermesi, geliştirilen yapının sağlam bir temel üzerine kurulduğunu göstermektedir. Ayrıca sonuçların web tabanlı karar destek sistemi mantığıyla birleştirilmiş olması, çalışmanın yalnızca teorik bir sınıflandırma denemesi değil, kullanıcıya dönük uygulanabilir bir çözüm önerisi sunduğunu ortaya koymaktadır.

5 TARTIŞMA

Bu çalışmada, üniversite öğrencilerinin stres düzeyini çok değişkenli anket ve yaşam alışkanlığı verileri üzerinden sınıflandırabilen web tabanlı bir karar destek sistemi tasarlanmıştır. Çalışmanın temel tartışma noktası, öğrenci stresinin tek boyutlu bir problem olarak değil; akademik, sosyal, davranışsal ve psikolojik değişkenlerin birlikte etkilediği çok boyutlu bir yapı olarak ele alınmasıdır. Bu çerçevede geliştirilen sistem, yalnızca veri toplayan bir uygulama olmak yerine, öğrencinin stres düzeyini düşük, orta ve yüksek olarak sınıflandıran, kısa öneriler sunan, geçmiş kayıtları saklayan ve eğilimleri izlenebilir hâle getiren bütünlük bir yapı önermektedir. Bu yönüyle çalışma, veri analizi ile yazılım mühendisliği yaklaşımını aynı sistem içinde birleştirmektedir.

Model seçimi açısından değerlendirildiğinde, bu projede Logistic Regression, Random Forest ve XGBoost algoritmaları karşılaştırılmış ve nihai model olarak Logistic Regression tercih edilmiştir. Bu seçimin temel nedeni, söz konusu modelin hem çapraz doğrulama hem de dış test sonuçlarında daha dengeli ve kararlı bir performans sunmasıdır. Bu durum, daha karmaşık modellerin her zaman en uygun çözüm olmayabileceğini; veri yapısına uyum, yorumlanabilirlik ve sürdürülebilirliğin de model seçimi açısından önemli olduğunu göstermektedir. Özellikle bitirme projesi ölçeğinde değerlendirildiğinde, Logistic Regression modelinin hem savunulabilir hem de sistem entegrasyonu açısından uygun bir tercih olduğu söylenebilir.

Çalışmanın önemli güçlü yönlerinden biri, tahmin sürecinin kullanıcıya doğrudan fayda sağlayacak bir sistem tasarımına dönüştürülmüş olmasıdır. Pek çok makine öğrenmesi çalışması yalnızca model başarımını raporlamakla sınırlı kalırken, bu projede kullanıcı kaydı, girişi, değerlendirme formu, sonuç ekranı, geçmiş kayıtlar ve dashboard bileşenleri birlikte ele alınmıştır. Böylece yapay zekâ modeli, arka planda çalışan soyut bir tahmin mekanizması olmaktan çıkarılmış; öğrencinin kendi verisini takip edebildiği, sonuçları anlamlandırabildiği ve zaman içindeki değişimi gözlemleyebildiği bir karar destek yapısına dönüştürülmüştür. Bu yaklaşım, projenin uygulamaya dönük değerini artırmaktadır.

Bununla birlikte çalışmanın bazı önemli sınırlılıkları bulunmaktadır. İlk olarak, kullanılan veri seti belirli bir öğrenci grubundan toplanmış açık erişimli anket verilerine dayanmaktadır. Bu nedenle elde edilen sonuçların tüm üniversite öğrencilerine, farklı ülkelere veya farklı eğitim sistemlerine doğrudan genellenmesi doğru olmayacaktır. İkinci olarak, veri seti öz-bildirim temelli olduğundan, öğrencilerin verdiği yanıtlar algısal farklılıklar ve kişisel değerlendirme hataları içerebilir. Üçüncü olarak, sistemin ürettiği sonuçlar klinik ya da psikiyatrik teşhis niteliği

taşınamamakta; yalnızca farkındalık oluşturmaya ve öz-izlemeyi destekleyen dijital bir araç olarak konumlandırılmaktadır. Bu sınırların açık biçimde belirtilmesi, çalışmanın akademik dürüstlüğü ve savunulabilirliği açısından gereklidir.

Gelecek çalışmalar açısından değerlendirildiğinde, sistemin farklı örneklemeler üzerinde yeniden test edilmesi, daha geniş veri kümeleri ile doğrulanması ve gerçek kullanıcı geri bildirimleriyle desteklenmesi projenin güvenilirliğini artıracaktır. Ayrıca model açıklanabilirliğini güçlendirmek amacıyla SHAP benzeri yöntemlerin eklenmesi, dashboard yapısının daha zengin grafiklerle geliştirilmesi ve kullanıcı testlerinin genişletilmesi de projenin sonraki aşamaları için anlamlı katkılar sağlayabilir. Bunun yanında farklı dönemlerde toplanan yeni verilerle model güncelleme sürecinin planlanması, sistemin uzun vadeli kullanılabilirliği açısından önemlidir.

Sonuç olarak bu çalışma, öğrenci stresini çok değişkenli tabular veri üzerinden sınıflandıran ve bu çıktıyı kullanıcı dostu bir web sistemi içinde sunan uygulanabilir bir karar destek yaklaşımı ortaya koymaktadır. Elde edilen yapı, hem akademik açıdan savunulabilir hem de yazılım mühendisliği perspektifinden geliştirilebilir bir temel sunmaktadır. Bu nedenle projenin temel değeri, yalnızca makine öğrenmesi modeli geliştirmesi değil; bu modeli anlamlı, izlenebilir ve kullanıcı odaklı bir dijital sisteme dönüştürmesidir. Çalışmanın bundan sonraki aşamalarında sonuçların görsel ve tablo temelli olarak daha güçlü sunulması, sistem arayüzlerinin eklenmesi ve nihai raporun ön sayfa ile dizin yapılarının tamamlanmasıyla birlikte doküman daha bütüncül bir hâle gelecektir.

Tablo 5.1. Proje yaklaşımı, avantajlar ve sınırlılıklar

Bakış Açısı	Analiz Edilen Durumun Özeti
Kapasite ve Yönelim	Karşılaştırmalı benchmark testleri (XGBoost, RandomForest vb.) sonucunda %90 üzerinde çapraz stabilite sunan Logistic Regression modeli nihai karar verici olarak sisteme entegre edilmiştir. Geliştirilen tahmin modeli, API tabanlı modüler bir web karar destek sistemi olarak sunulmaktadır.
Proje Sınırları	Kullanılan model araştırması spesifik (öğrenci/anket) demografik bir veri seti üzerinden gerçekleştirilmiştir. Dolayısıyla elde edilecek tahmin sonuçları evrensel mutlaklık taşımaz. Kesin ifadeli "klinik rehberler" değil, tamamen farkındalık oluşturmaya teşvik edecek eğitsel/tasarımsal referanslar ("Farkındalık Taraması") olarak görev yapmaya kodlanmıştır.

6 İŞ PAKETLERİ VE ZAMANLAMA PLANI

Bir yazılım projesinin başarılı biçimde tamamlanabilmesi yalnızca teknik doğruluğa değil, aynı zamanda sürecin planlı ve kontrollü biçimde yürütülmesine de bağlıdır. Bu nedenle iş paketleri ve zamanlama planı, proje geliştirme sürecinin hangi aşamalardan oluştuğunu, her aşamada hangi çıktıların hedeflendiğini ve bu çıktıların hangi zaman diliminde tamamlanmasının öngörüldüğünü açıklayan temel bölümdür. “Üniversite Öğrencileri için AI Destekli Stres Tahmin Sistemi” projesinde planlama yaklaşımı; literatür çalışması, veri bilimi süreci, sistem mimarisi, arka uç ve ön uç geliştirme, entegrasyon, test ve dokümantasyon adımlarını kapsayacak şekilde yapılandırılmıştır. Güncel plan dosyasında da proje süreci faz bazlı, iş paketi bazlı ve haftalık takvim bazlı üç ayrı düzeyde düzenlenmiştir.

Bu planlama yapısının temel amacı, proje kapsamını kontrol altında tutmak ve her aşamanın bir sonraki teknik adıma altyapı oluşturmasını sağlamaktır. Özellikle bitirme projesi niteliğindeki çalışmalarda literatür, veri seti, model geliştirme, web uygulaması ve raporlama süreçleri birbirine bağlı ilerlediği için, zamanlama planının baştan açık biçimde tanımlanması önemlidir. Böylece proje yalnızca ortaya çıkan bir ürün olarak değil, baştan sona yönetilmiş bir mühendislik süreci olarak sunulabilmektedir.

6.1 Fazlara Göre İş Paketleri

Bu proje kapsamında çalışma süreci beş ana faz altında ele alınmıştır. İlk faz, planlama ve teknik çözümleme aşamasıdır. Bu aşamada problemin kapsamı netleştirilmiş, literatür incelemesi yapılmış, veri seti seçilmiş ve sistemin ihtiyaç duyduğu temel analiz çizimleri ile gereksinim yapısı oluşturulmuştur. Bu faz, projenin geri kalan bütün teknik adımları için yön belirleyici niteliktedir. Güncel plan tablosunda da ilk fazın temel amacı, servisin mantıksal gereksinimlerinin saptanması ve analiz çizimlerinin oluşturulması olarak tanımlanmıştır.

İkinci faz veri bilimi aşamasıdır. Bu aşamada veri setinin yapısı incelenmiş, ön işleme süreci yürütülmüş, modelleme için uygun öznitelik yapısı belirlenmiş ve farklı sınıflandırma algoritmaları karşılaştırılmıştır. Logistic Regression, Random Forest ve XGBoost modelleri bu kapsamda değerlendirilmiş; yapılan performans analizleri sonucunda Logistic Regression modeli nihai model olarak seçilmiştir. Bu faz, sistemin çekirdek karar verme bileşenini belirlediği için proje açısından kritik teknik ağırlığa sahiptir. Güncel plan dosyasında da veri bilimi fazı, ön işleme, model eğitimi ve algoritma onayı çerçevesinde tanımlanmıştır.

Üçüncü faz, servis altyapısının kurulmasıdır. Bu aşamada arka uç yazılım bileşenleri, veritabanı bağlantıları, kullanıcı yönetimi ve tahmin servisinin entegrasyonu gerçekleştirilmiştir. Kullanıcıdan gelen form verilerinin işlenmesi, model çağrısının yapılması, tahmin sonucunun

oluşturulması ve veritabanına kaydedilmesi gibi kritik işlevler bu faz içinde geliştirilmiştir. Dördüncü faz ise ön uç geliştirme sürecini kapsamaktadır. Bu fazda ana sayfa, giriş ve kayıt sayfaları, değerlendirme formu, sonuç ekranı ve dashboard gibi kullanıcı arayüzleri oluşturulmuştur. Böylece teknik modelleme süreci kullanıcıya görünür ve erişilebilir bir web deneyimine dönüştürülmüştür. Güncel tabloda bu iki faz sırasıyla backend altyapısı ve platform arayüz kodlaması olarak tanımlanmaktadır.

Beşinci ve son faz ise entegrasyon, hata giderme, kullanıcı senaryosu testleri ve nihai akademik dokümantasyon aşamasıdır. Bu aşamada sistem bileşenlerinin birlikte çalışması doğrulanmakta, test senaryoları uygulanmakta ve proje raporu tamamlanmaktadır. Özellikle kullanıcı kabul testleri, sistemin yalnızca teorik olarak değil, kullanım senaryoları içinde de doğrulanmasını sağlamaktadır. Bu nedenle son faz, projenin tamamlanma ve teslim aşamasını temsil etmektedir.

Tablo 6.1. Dönemsel iş paketleri

Kritik Aşama	İş Paketi Kategorisi	Ana Hedef
Faz 1	Planlama ve Teknik Çözümleme	Geliştirilecek servisin mantıksal gereksinimlerinin saptanarak analiz çizimlerinin oluşturulması.
Faz 2	Veri Bilimi Aşaması	Datasetteki yapıların temizlenmesi (Ön-İşleme) modellerin eğitimi ve skarlara göre algoritma onaylanması.
Faz 3	Servis Altyapısının Kurulması	Arka uç yazılımı (Backend) tarafında veritabanı yollarının ve erişim yetkilendirmesi entegrasyonlarının tasarlanması.
Faz 4	Platform Arayüz Kodlaması	Kullanıcı tarafından deneyimlenen grafiksel ve görsel unsurların web ortamında prototiplenmesi.
Faz 5	Kararlılık Hata ve Kabul Testleri	Tüm modüllerin birleştirilerek test döngüsünden geçmesi ve son akademik dokümantasyonun tamamlanması.

6.2 Ayrıntılı İş Paketi Dağılımı

Faz bazlı yapı, projenin genel akışını göstermektedir; ancak her fazın içinde yer alan teknik görevlerin ayrıca iş paketleri düzeyinde tanımlanması gerekmektedir. Bu doğrultuda proje süreci daha ayrıntılı biçimde WP-1'den WP-6'ya kadar kodlanan iş paketlerine bölünmüştür. İlk iş paketi literatür ve ön tasarım sürecini kapsamaktadır. Bu aşamada proje taslak belgesi hazırlanmakta, analiz diyagramları oluşturulmakta ve yazılacak sistemin temel mantığı netleştirilmektedir. İkinci iş paketi model uygulama geliştirme sürecidir. Burada veri işleme, algoritmaların eğitilmesi ve model çıktılarının karşılaştırılması yürütülmektedir. Bu iki iş paketi, projenin veri ve yöntem temelini oluşturmaktadır.

Üçüncü iş paketi çekirdek sistem API'lerine ayrılmıştır. Bu kapsamda sunucu uç noktaları, kullanıcı kimlik doğrulama işlevleri ve tahmin hizmetiyle ilgili servisler geliştirilmektedir. Dördüncü iş paketi ise ön uç sistem tasarımını kapsamakta; React tabanlı bileşenler, kullanıcı ekranları ve dashboard görünümü bu aşamada oluşturulmaktadır. Bu iki paket birlikte ele alındığında, veri bilimi katmanının çalışan bir web uygulamasına dönüştürüldüğü görülmektedir. Beşinci iş paketi entegrasyon, test ve revizyon sürecini içermektedir. Bu aşamada sistem parçalarının birlikte çalışması doğrulanmakta, hatalar giderilmekte ve uygulama kararlı hâle getirilmektedir. Altıncı ve son iş paketi ise dokümantasyon ve akademik sunum hazırlıklarını kapsamaktadır. Bu aşamada rapor yazımı, tablo ve grafiklerin yerleştirilmesi ve proje sunum materyallerinin hazırlanması tamamlanmaktadır. Güncel plan tablosu da bu dağılımı aynı sıra ve mantıkla göstermektedir.

Ayrıntılı iş paketi dağılımı, projenin hangi parçalarının birbirine bağlı ilerlediğini açık biçimde göstermesi bakımından önemlidir. Bu yapı sayesinde bir aşamanın çıktısı, sonraki aşamanın girdisi hâline gelmektedir. Örneğin model eğitimi tamamlanmadan backend entegrasyonu anlamlı olmayacak; backend ve veritabanı tamamlanmadan da dashboard yapısının işlevsel hâle gelmesi mümkün olmayacaktır. Bu nedenle iş paketlerinin sıralanışı yalnızca zaman çizelgesi değil, aynı zamanda mantıksal bağımlılık ilişkisini de ifade etmektedir.

Tablo 6.2. Ayrıntılı iş paketi dağılımı

WP Kodu	Amaç	Tahmini Çıktı	Periyot
WP-1	Literatür ve Ön Tasarım	Proje Taslak Belgesi, Analiz Diyagramları.	1 Hafta
WP-2	Model Uygulama Geliştirme	Makine öğrenmesi modelleri algoritmaları ve veri işleme.	2 Hafta
WP-3	Çekirdek Sistem API'leri	Sunucu uç noktaları (endpointler) ve kimlik yönetimi servisi.	2 Hafta
WP-4	Ön Uç (Frontend) Sistem Tasarımı	React/Web bileşenleri, Dashboard panel görünümleri.	3 Hafta
WP-5	Entegrasyon, Test ve Revizyon	Sistem entegrasyonu, genel bakım testleri ve hataların giderimi.	2 Hafta
WP-6	Dokümantasyon ve Akademik Sunum	Tezin raporlanması, grafik/tablolara organizasyonu (Final evresi).	1 Hafta

6.3 Haftalık Zamanlama ve Gantt Yaklaşımı

Proje sürecinin daha somut izlenebilmesi için iş paketleri haftalık bir takvim yapısına da dönüştürülmüştür. Bu yaklaşımda her hafta için temel görev alanı ve beklenen çıktı tanımlanmıştır. İlk haftalarda literatür taraması, veri setinin incelenmesi ve tasarım gereksinimlerinin çıkarılması hedeflenirken; orta haftalarda model eğitimi, backend geliştirme ve frontend inşası yürütülmektedir. Son haftalar ise entegrasyon, test, dokümantasyon ve teslim hazırlıklarına ayrılmıştır. Bu yapı, projenin dönem boyunca dengeli biçimde yayılmasına ve son aşamada birikmiş iş yükü oluşmasının önlenmesine katkı sağlamaktadır. Güncel haftalık plan tablosunda da 12 haftalık bir zaman akışı tanımlanmış ve her haftanın hedeflenen çıktısı belirtilmiştir.

Haftalık planın en önemli katkılarından biri, projenin yalnızca teknik adımlarını değil, akademik raporlama sürecini de planın doğal bir parçası hâline getirmesidir. Çoğu zaman proje geliştirme sürecinde teknik uygulama ön plana çıkarken, raporlama ve sunum hazırlıkları sona bırakılmaktadır. Ancak bitirme projesi değerlendirmesinde yazılı dokümantasyon, teknik uygulama kadar önem taşıdığı için rapor hazırlama ve tablo-grafik düzenleme sürecinin de zaman çizelgesine dahil edilmesi gerekmektedir. Bu nedenle haftalık plan yapısında dokümantasyon ve sunum süreci son haftalara açık biçimde yerleştirilmiştir.

Gantt yaklaşımı, bu haftalık dağılımın görsel biçimde sunulmasını sağlayan önemli bir planlama aracıdır. İş paketlerinin zaman ekseninde gösterilmesi, proje sürecinin daha anlaşılır ve izlenebilir biçimde sunulmasına yardımcı olmaktadır. Özellikle jüri veya danışman açısından bakıldığında, proje sürecinin hangi sırayla ve hangi mantıkla ilerlediğinin görsel olarak sunulması, çalışmanın planlı yürütüldüğünü göstermesi bakımından değerlidir. Bu nedenle Gantt şeması, yalnızca planlama amacı taşımamakta; aynı zamanda projenin yönetsel olgunluğunu gösteren bir çıktı olarak da önem kazanmaktadır.

Tablo 6.3. Haftalık zamanlama planı

Takvim	Planlanan Ana Görev Kapsamı	Hedeflenen Çıktı
Hafta 1	Önceki çalışmaların referans taranması ve kullanılacak veri setinin keşfi.	Temel İskelet Özeti

Hafta 2	Use case ve yapısal gereksinimlerin şematik olarak tasarlanması.	Tasarım Şablonları
Hafta 3	Eksik veri onarımı, veri ölçeklendirmesi ve bölütlemelerinin yapılması.	Temizlenmiş ve Bölünmüş Veri
Hafta 4	Belirlenen tahmin modellerinin (XGBoost vb.) Python üzerinden eğitim süreçleri.	Test Başarım Skorları
Hafta 5	Arka plan sunucu dizinlerinin oluşturulması (FastAPI) ve veritabanı eşleştirmesi.	API İskeleti ve Veritabanı
Hafta 6	Endpoint rotalarının servise alınması, ML model dosyasının sisteme çağrılması.	Dinamik Sunucu Yanıtı
Hafta 7	Arayüz (Frontend) hazırlıkları, Navbar ve temel bileşenlerin çalıştırılması.	Ana Web Görünümü
Hafta 8	Kritik form mantıklarının (Anket doldurma, giriş ve kayıt işlemleri) eklenmesi.	Veri Akış Arayüzü
Hafta 9	Çıkan tahminlerin (Sonuç sayfası) ve tarihsel sürecin istatistik grafiklerine dönüştürülmesi.	Grafik Ekranı ve Tablolar
Hafta 10	Web katmanlarının ve sunucu rotalarının bir bütün olarak denenmesi ve oturum yönetimi entegrasyonlarının tamamlanması.	Kararlı Web Uygulaması
Hafta 11	Akademik raporlama diline uygun şablona aktarılma süreci ve tablo kontrolleri.	Proje Kitapçığı
Hafta 12	Teslim dosyalarının derlenmesi, sunum taslakları ve uygulamanın son canlı onayı.	Final Teslimi

6.4 Planın Proje Yönetimi Açısından Değerlendirilmesi

Hazırlanan iş paketleri ve zamanlama planı, projenin teknik ve akademik boyutlarını birlikte yönetebilmek için önemli bir çerçeve sunmaktadır. Bu plan sayesinde hem veri bilimi süreci hem de web uygulaması geliştirme süreci birbirinden kopmadan ilerlemekte; aynı zamanda dokümantasyon ve test faaliyetleri de projenin doğal parçaları olarak ele alınmaktadır. Böylece proje, yalnızca çalışan bir ürün üretmeyi değil, aynı zamanda mühendislik yönetimi ilkelerine uygun biçimde planlanmış ve yürütülmüş bir süreç ortaya koymayı amaçlamaktadır.

Zamanlama planının bir diğer katkısı, projenin teslim sürecine kadar hangi aşamalardan geçtiğinin açık biçimde gösterilmesidir. Bu durum, danışman geri bildirimlerinin doğru aşamada alınmasına, teknik risklerin erken fark edilmesine ve proje kapsamının kontrol altında tutulmasına yardımcı olmaktadır. Özellikle bitirme projelerinde zaman yönetimi teknik başarı kadar belirleyici olduğundan, hazırlanan bu plan hem uygulama sürecinin hem de akademik değerlendirmenin önemli bir bileşeni olarak görülmelidir. Sonuç olarak iş paketleri ve zamanlama planı, çalışmanın sadece “ne” yaptığını değil, bunu “hangi sıra ve yönetim mantığıyla” yaptığını da gösteren tamamlayıcı bir bölüm niteliğindedir.

7 KAYNAKLAR

Bu bölümde, proje hazırlanırken yararlanılan tüm kitap, makale, tez, web sitesi ve diğer kaynaklar liste halinde verilir. Kaynaklar belirli bir yazım kuralına (ör. IEEE, APA vb.) uygun biçimde düzenlenir ve metin içinde kullanılan atıflarla uyumlu olmalıdır. Böylece çalışmanın dayandığı bilgiler açıkça gösterilir ve akademik güvenilirlik sağlanır.

[1] Auerbach, R. P., Mortier, P., Bruffaerts, R., Alonso, J., Benjet, C., Cuijpers, P., Demyttenaere, K., Ebert, D. D., Green, J. G., Hasking, P., Murray, E., Nock, M. K., Pinder-Amaker, S., Sampson, N. A., Stein, D. J., Vilagut, G., Zaslavsky, A. M., & Kessler, R. C. (2016). WHO World Mental Health Surveys International College Student Project: Prevalence and distribution of mental disorders. *Journal of Abnormal Psychology*, 127(7), 623–638. <https://doi.org/10.1037/abn0000362>

[2] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). <https://doi.org/10.1145/2939672.2939785>

[3] Breiman, L. (2001). Random forests. *Machine Learning*, 45, 5–32. <https://doi.org/10.1023/A:1010933404324>

[4] Cohen, S., Kamarck, T., & Mermelstein, R. (1983). A global measure of perceived stress. *Journal of Health and Social Behavior*, 24(4), 385–396. <https://pubmed.ncbi.nlm.nih.gov/6668417/>

[5] Gardani, M., Bradford, D. R. R., Russell, K., Allan, S., Beattie, L., Ellis, J. G., & Akram, U. (2022). A systematic review and meta-analysis of poor sleep, insomnia symptoms and stress in undergraduate students. *Sleep Medicine Reviews*, 61, 101565. <https://doi.org/10.1016/j.smr.2021.101565>

[6] Scikit-learn developers. (n.d.). *LogisticRegression*. *scikit-learn*. Retrieved April 6, 2026, from https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html

- [7] World Health Organization. (2025, September 1). *Mental health of adolescents*. <https://www.who.int/news-room/fact-sheets/detail/adolescent-mental-health>
- [8] Wunsch, K., Fiedler, J., Bachert, P., & Woll, A. (2021). The tridirectional relationship among physical activity, stress, and academic performance in university students: A systematic review and meta-analysis. *International Journal of Environmental Research and Public Health*, 18(2), 739. <https://doi.org/10.3390/ijerph18020739>
- [9] Lisnyj, K. T., Gillani, N., Pearl, D. L., McWhirter, J. E., & Papadopoulos, A. (2023). Factors associated with stress impacting academic success among post-secondary students: A systematic review. *Journal of American College Health*, 71(3), 851–861.
- [10] Tariq, R., Orozco-del-Castillo, M. G., et al. (2025). Explainable artificial intelligence for predictive modeling of student stress in higher education. *Scientific Reports*, 15, Article s41598-025-22171-3.
- [11] Liu, C., & Yu, S. (2026). Students' stress prediction and explainable analysis based on improved decision trees. *Frontiers in Psychology*, 16, 1684529. <https://doi.org/10.3389/fpsyg.2025.1684529>
- [12] Saito, T., & Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. *PLOS ONE*, 10(3), e0118432.

8 ÖZGEÇMİŞ

İsmail Can Günay, Aydın'ın Didim ilçesinde doğmuştur. İlkokul, ortaokul ve lise eğitimini Didim'de tamamlamıştır. 2022 yılında İstanbul Topkapı Üniversitesi Yazılım Mühendisliği Bölümü'nde lisans eğitimine başlamış olup eğitime aktif olarak devam etmektedir.

Lisans eğitimi süresince yazılım geliştirme, yapay zekâ ve makine öğrenmesi alanlarına ilgi duymuş; bu alanlarda teknik bilgisini geliştirmeye yönelik çeşitli çalışmalar yürütmüştür. Python, C/C++ ve Java programlama dillerini kullanmakta; veri odaklı problem çözme ve proje geliştirme süreçlerine özel ilgi duymaktadır.

Daha önce gerçekleştirdiği çalışmalar arasında, yapay sinir ağları ve derin öğrenme yöntemleri kullanılarak ağ trafiğinde DDoS saldırılarını tespit etmeye yönelik bir proje ile Arduino tabanlı, çevresindeki nesneleri algılayabilen bir araç prototipi yer almaktadır. Bu projelerde veri ön işleme, model optimizasyonu, doğruluk analizi, elektronik devre tasarımı ve yazılım entegrasyonu gibi alanlarda deneyim kazanmıştır.

Bu bitirme projesinde ise üniversite öğrencileri için yapay zekâ destekli stres tahmin sistemi geliştirerek, veri analizi, makine öğrenmesi ve web tabanlı karar destek sistemi tasarımını bir araya getiren bütünlük bir çalışma ortaya koymuştur.